SABANA HACK 2026 · RETO «ARROZ CON LECHE» · COSCO SHIPPING

Sistema de selección de proveedores de transporte terrestre

Recomendación rápida, consistente y explicable del proveedor más adecuado para cada solicitud, con la persona de operaciones como responsable de la decisión final.



Documento de solución · Octubre de 2026
Equipo multidisciplinario: ingeniería de sistemas, ingeniería de control, ingeniería mecatrónica, ingeniería mecánica y negocios
Archivo complementario editable: **COSCO_BPMN_AS-IS_TO-BE.drawio** (procesos, lazo de control y modelo de datos)

CONTENIDO

Cómo está organizado este documento

Cada sección responde a una parte concreta del reto. Al final hay una tabla que relaciona cada entregable y cada criterio de evaluación con la sección donde se cubre.

1. Resumen ejecutivo
2. El problema tal como lo entendimos
3. Visión general de la solución
4. Modelo de datos
5. Metodología de puntuación y recomendación
6. Ranking, fortalezas, debilidades y riesgos
7. Casos difíciles y cómo se resuelven
8. Procesos: AS-IS, TO-BE y lazo de control
9. Aprendizaje continuo y retroalimentación
10. Tableros visuales
11. Datos para la demostración
12. Validación
13. Motores de decisión: nuestro modelo frente a Jev y a un LLM
14. Valor de negocio, escalabilidad e implementación
15. Cumplimiento de entregables y criterios
16. Arquitectura técnica y plan de trabajo

Anexo. Glosario

1. Resumen ejecutivo

Hoy el equipo de operaciones de COSCO SHIPPING en Colombia decide qué proveedor atiende cada solicitud de transporte terrestre comparando más de diez transportistas uno por uno. El resultado depende de quién decide, toma tiempo y no deja registro del porqué.

Proponemos un **sistema de apoyo a la decisión** que, para cada solicitud, entrega un **Top-3 ordenado y explicado**. Su principio es simple: **los modelos predicen lo incierto, una función de decisión transparente ordena y la persona de operaciones decide**.

- **Reglas duras primero.** Se descartan los proveedores sin el vehículo, la capacidad, la cobertura o las certificaciones que el envío exige, y se informa el motivo.
- **Predicción de lo incierto.** Para cada proveedor factible se estima la probabilidad de entregar a tiempo, el tiempo de tránsito típico y pesimista, y el riesgo de incidente, por corredor y tipo de carga.
- **Una sola moneda.** Todo se convierte en **costo total esperado en pesos**: precio más el costo esperado de retrasos, incidentes, incertidumbre y concentración. Como la tarifa al cliente está fija por solicitud, minimizar este costo equivale a maximizar el margen.
- **Niveles de servicio.** Flexible, Estándar y Urgente cambian cuánto cuesta un retraso y, por tanto, qué pesa más cuando precio, tiempo y confiabilidad apuntan en direcciones distintas.
- **Humano en el lazo.** Los casos claros se aprueban en un clic; los urgentes, empatados, con pocos datos o sin opción ideal pasan a revisión detallada; los de margen negativo escalan a gerencia.
- **Aprendizaje continuo y estable.** Cada servicio cerrado actualiza las estadísticas del proveedor en tiempo real; los modelos se reentrenan cada noche y los pesos solo cambian con aprobación de gerencia.

> **Qué gana COSCO:** decisiones en segundos y no en minutos, la misma respuesta ante la misma solicitud, menos costo por servicio, mayor puntualidad, trazabilidad completa de cada decisión y datos objetivos para negociar con los proveedores.

COMPRENSIÓN DEL PROBLEMA

2. El problema tal como lo entendimos

Cómo se decide hoy

El cliente envía la solicitud por correo, teléfono o WhatsApp. El analista la transcribe, busca tarifas en hojas de cálculo, llama a los proveedores uno por uno para preguntar si tienen el vehículo y la capacidad, y elige con su criterio. El proceso completo está en el diagrama AS-IS (sección 8). Sus cuatro problemas son: **lentitud**, **inconsistencia**, **falta de trazabilidad** y **falta de aprendizaje**.

Los siete factores y por qué chocan

Factor del reto	Tensión con otros factores	Cómo lo usa el sistema
Precio del transporte	El más barato puede no tener el vehículo o fallar más.	Componente directo del costo total esperado.
Tiempo de tránsito	El más rápido en promedio puede ser muy variable.	Modelo M2: tiempo típico (P50) y pesimista (P90). El P90 se compara con el plazo.
Disponibilidad del vehículo	Sin el vehículo correcto no hay servicio, por barato que sea.	Filtro duro (regla fija) con motivo de descarte.
Capacidad disponible	El mejor proveedor puede estar lleno esa semana.	Filtro duro al recomendar y confirmación del proveedor antes de ejecutar; si rechaza, se reasigna.
Desempeño histórico	Un historial corto engaña; uno largo puede estar desactualizado.	Estadística bayesiana con decaimiento temporal; incidentes, cancelaciones y rechazos.
Confiabilidad y entregas a tiempo	Cuesta más ser confiable; no todos los envíos lo necesitan igual.	Modelo M1: probabilidad de llegar a tiempo, multiplicada por el costo del retraso según el nivel.
Fortalezas y debilidades específicas	Un buen promedio general puede esconder un punto débil justo en este corredor o tipo de carga.	Todas las estadísticas se calculan por proveedor × corredor × tipo de carga, y la explicación lo muestra.

Quién decide y qué necesita

Analista de operaciones

Necesita una respuesta rápida, ver por qué un proveedor quedó por encima de otro, saber cuándo desconfiar de la recomendación (pocos datos, empate, sin opción ideal) y poder elegir otra opción sin fricción.

Gerencia de operaciones

Necesita revisar periódicamente el desempeño por proveedor y corredor, detectar deterioros a tiempo, controlar la concentración del volumen y negociar tarifas con argumentos basados en datos.

Casos difíciles que el sistema debe resolver

- Ningún proveedor cumple todos los requisitos (vehículo, capacidad o plazo).
- Un proveedor con muy pocos servicios parece perfecto o pésimo.
- Un proveedor con buen historial empieza a fallar.
- Dos o tres opciones quedan prácticamente empatadas.
- Demasiados servicios terminan concentrados en pocos proveedores.

La respuesta a cada uno está en la sección 7.

SOLUCIÓN

3. Visión general de la solución

Un modelo de ML que elige directamente al proveedor sería difícil de explicar y aprendería a copiar el criterio inconsistente de hoy. Por eso la solución es **híbrida**: cada pieza hace lo que mejor sabe hacer.

1 · Datos	Proveedores, flota, tarifas, capacidad en el tiempo, solicitudes, servicios ejecutados, eventos en ruta, feedback y registro de decisiones (sección 4).
2 · Factibilidad	REGLAS Descarta a quien no puede hacer el servicio: vehículo, capacidad, cobertura del corredor, certificaciones (mercancía peligrosa, refrigerada, sobredimensionada). Cada descarte queda con su motivo.
3 · Predicción	IA Para cada proveedor factible: probabilidad de llegar a tiempo, tránsito P50 y P90, riesgo de incidente y precio esperado si no hay tarifa cotizada.
4 · Decisión	IA Convierte todo en costo total esperado según el nivel de servicio, ordena de forma determinista y arma el Top-3 con su explicación.
5 · Persona	HUMANO Operaciones aprueba o elige otra opción con un motivo; gerencia aprueba excepciones y ajustes de pesos. Todo queda registrado.

Niveles de servicio

El nivel de servicio responde a la pregunta del reto *"cuando el precio, el tiempo y la confiabilidad apuntan en direcciones distintas, ¿qué pesa más?"*. La respuesta depende de cuánto le cuesta al cliente un retraso.

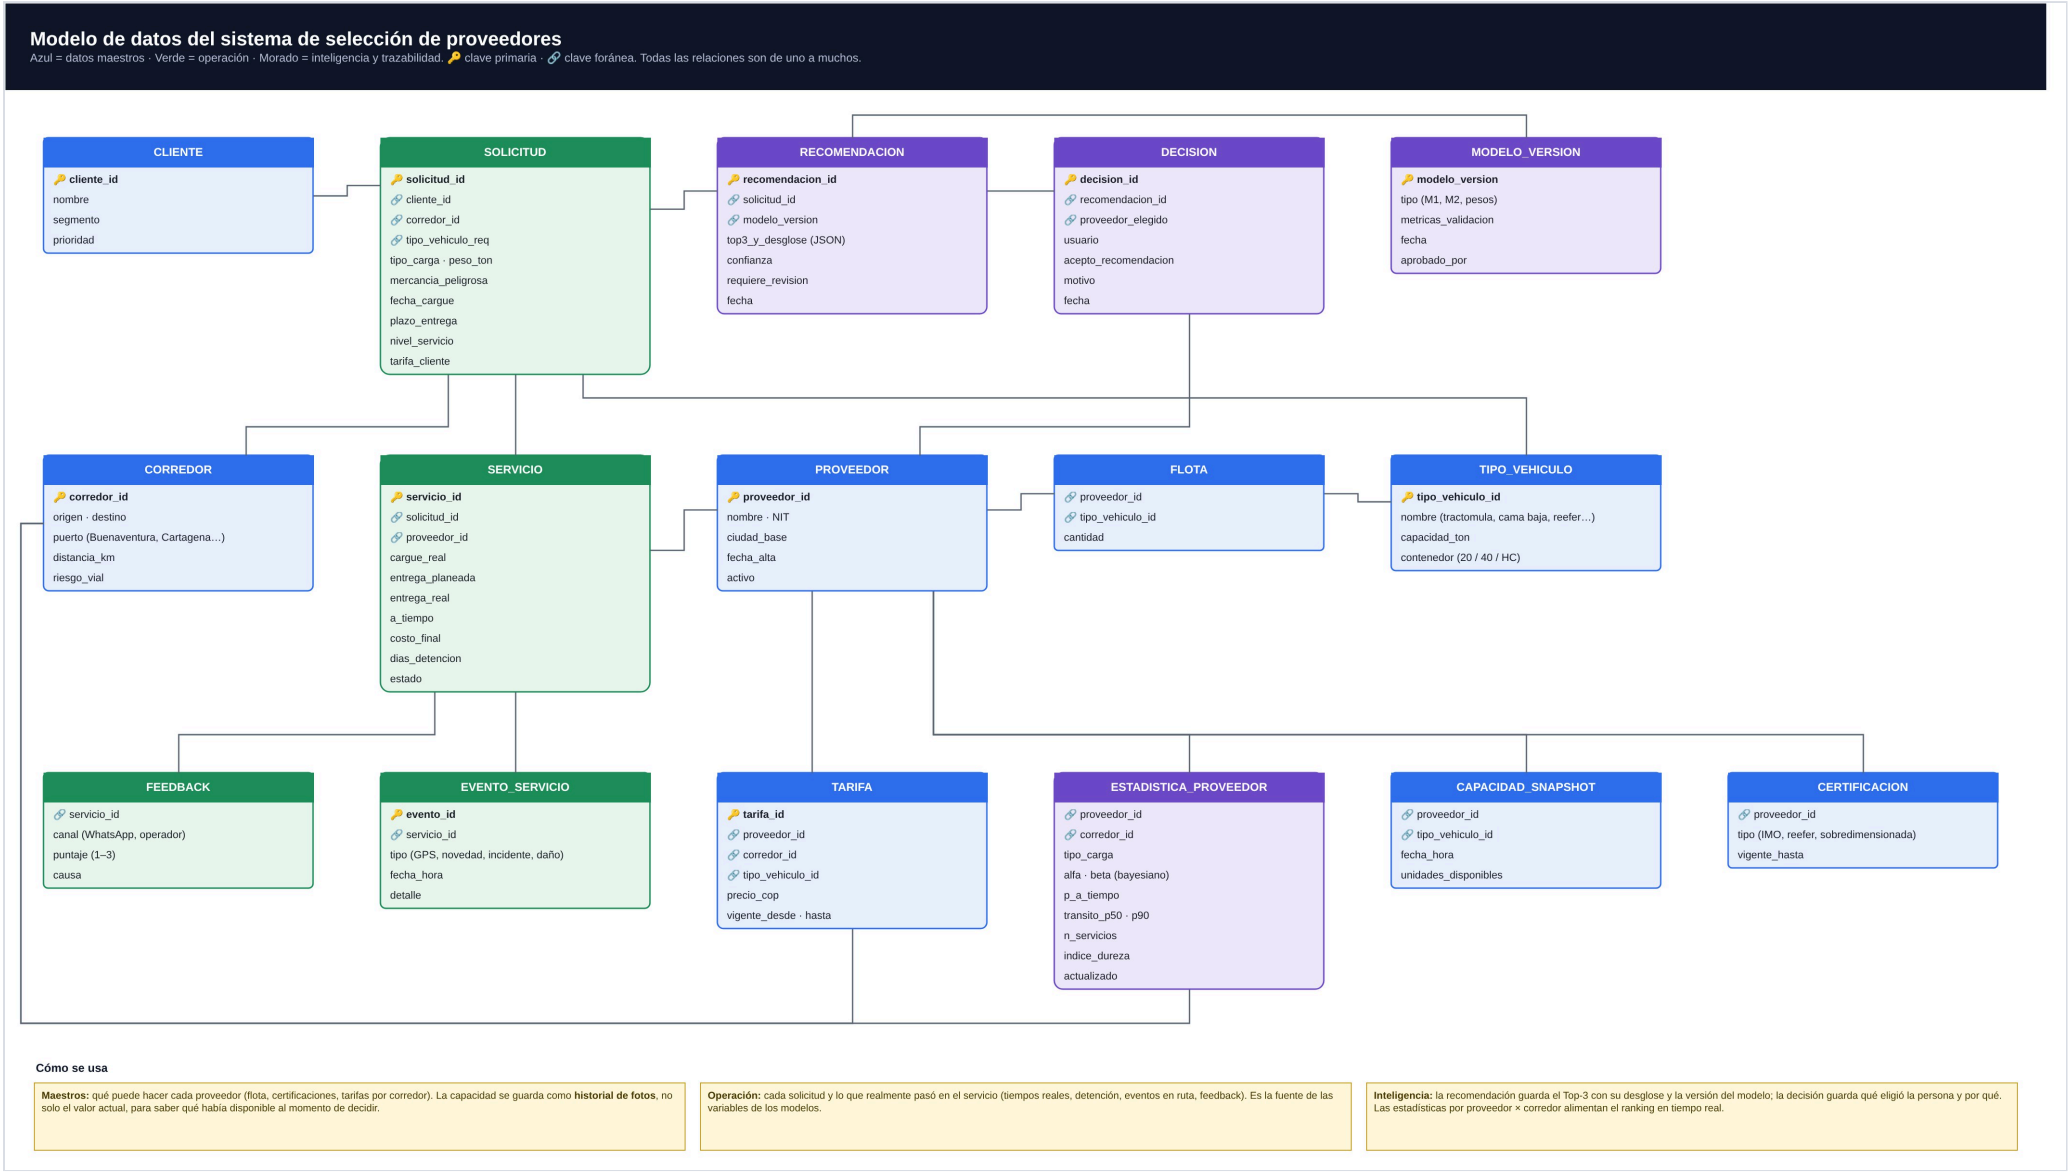
Nivel	Para quién	Qué pesa más	Costo de retraso (ejemplo)	Revisión
Flexible	Carga sin afán; ventana de +3 días.	Precio. El retraso dentro de la ventana casi no cuesta.	$ 300.000	1 clic, salvo alertas
Estándar	La mayoría de los envíos.	Balance entre precio y puntualidad.	$ 2.500.000	1 clic, salvo alertas
Urgente	Producción detenida o fecha fija.	Confiabilidad; se reserva un proveedor de respaldo.	$ 6.000.000	Siempre detallada

Los costos de retraso son parámetros de negocio configurables (penalidades, compensaciones, días de detención del contenedor). Los valores de este documento son ilustrativos y deben calibrarse con COSCO.

> Como modelo de negocio, los niveles también permiten cobrar una prima por la garantía del nivel Urgente. Pero el núcleo de la solución es la decisión de qué proveedor asignar; el cobro diferenciado es una extensión.

ENTREGABLE · BASE DE DATOS Y MODELO DE DATOS

4. Modelo de datos



Modelo entidad-relación (página 4 del archivo drawio). Azul: maestros · Verde: operación · Morado: inteligencia y trazabilidad.

Decisiones de diseño del modelo de datos

- **La capacidad se guarda como historial de fotos** (CAPACIDAD_SNAPSHOT) y no solo como el valor actual. Así, al evaluar decisiones pasadas se sabe qué había disponible en ese momento, y se evita juzgar una decisión con información que no existía.
- **Las tarifas tienen vigencia.** Permite reproducir el precio que aplicaba en cada fecha.
- **RECOMENDACION y DECISION están separadas.** La primera guarda el Top-3 con su desglose y la versión del modelo; la segunda guarda qué eligió la persona, si aceptó la recomendación y por qué. Esta separación permite medir el valor del sistema y aprender de los desacuerdos.
- **ESTADISTICA_PROVEEDOR** guarda, por proveedor × corredor × tipo de carga, los parámetros bayesianos, los tiempos P50/P90, el número de servicios y el Índice de Dureza. Es lo que se actualiza en tiempo real.
- **MODELO_VERSION** registra cada modelo y cada juego de pesos con sus métricas y quién lo aprobó. Cualquier recomendación puede reproducirse y auditarse.

Calidad de datos

Antes de calcular cualquier indicador se aplican reglas de limpieza: tiempos de tránsito negativos o imposibles para la distancia, fechas invertidas, servicios duplicados, proveedores con nombres distintos para la misma empresa y campos vacíos. Cada solicitud y cada proveedor llevan un indicador de completitud; si la información es pobre, la recomendación lo dice.

ENTREGABLE · METODOLOGÍA DE PUNTUACIÓN Y RECOMENDACIÓN

5. Metodología de puntuación y recomendación

5.1 Paso 1: filtro de factibilidad REGLAS

Un proveedor pasa a evaluación solo si cumple todas estas condiciones: tiene el tipo de vehículo requerido en su flota; tiene capacidad disponible para la fecha de cargue; cubre el corredor; y tiene las certificaciones vigentes que exige la carga. Estas reglas **nunca se aprenden ni se relajan automáticamente**: un proveedor sin certificación para mercancía peligrosa no entra, aunque sea el más barato. Los descartados aparecen en pantalla con su motivo, porque "por qué no" también es parte de la explicación.

5.2 Paso 2: modelos predictivos IA

Modelo	Qué predice	Técnica	Por qué
M1 Puntualidad	Probabilidad de entregar a tiempo.	Gradient boosting (CatBoost) con calibración isotónica.	Maneja bien variables categóricas (proveedor, corredor) y pocos datos. La calibración hace que "80 %" signifique realmente 80 %.
M2 Tránsito	Tiempo típico (P50) y pesimista (P90).	Regresión cuantílica (LightGBM, objetivo *quantile*).	El promedio oculta la variabilidad; el P90 dice si el plazo es alcanzable con confianza.
M3 Precio	Precio esperado si no hay tarifa cotizada.	Mediana del corredor ajustada por proveedor; regresión si hay datos.	Permite comparar aun cuando falte la cotización.

Modelo	Qué predice	Técnica	Por qué
M4 Riesgo	Probabilidad de incidente o cancelación.	Clasificador o tasa bayesiana, según los datos disponibles.	Solo si los datos registran incidentes; si no, se usa una tasa base explícita.

> **Plan B con pocos datos.** Si el histórico tiene pocos cientos de registros, M1 y M2 se reemplazan por estimaciones bayesianas por proveedor × corredor. La arquitectura no cambia: cada modelo es una pieza intercambiable con la misma entrada y salida.

5.3 Variables que usan los modelos

Grupo	Variables
Solicitud	Corredor, distancia, puerto, importación/exportación, tipo de contenedor (20/40/HC/reefer), peso, mercancía peligrosa, vehículo requerido, holgura del plazo (plazo − tiempo típico del corredor), día de la semana, mes, festivo o puente, temporada de lluvias, prioridad del cliente.
Proveedor	Puntualidad móvil a 30/90/365 días con suavizado bayesiano, volumen, tasa de cancelación, tasa de incidentes, media y variabilidad del tránsito, índice de precio (tarifa / mediana del corredor), tendencia reciente, utilización actual de su capacidad.
Proveedor × solicitud	Experiencia en este corredor, con este tipo de carga y este vehículo; puntualidad en el corredor comparada con su promedio general. Son las variables que capturan las fortalezas y debilidades específicas.
Contexto	Cierres viales, paros, congestión en puerto, si se puede conseguir la fuente.

Todas las variables se calculan solo con información disponible antes de la fecha de la solicitud, para evitar fuga de información en el entrenamiento y la validación.

5.4 Pocos datos: suavizado bayesiano

Un proveedor con 3 de 3 entregas a tiempo no tiene 100 % de puntualidad: tiene poca evidencia. El sistema parte de una creencia previa (el promedio de todos los proveedores) y la ajusta con la evidencia propia.

```
P(tarde) = (retrasos + β₀) / (servicios + α₀ + β₀)

Creencia previa del ejemplo: 85 % a tiempo con fuerza de 20 servicios → α₀ = 17, β₀ = 3
```

Con pocos servicios, el resultado se acerca al promedio general; con muchos, refleja al proveedor. Además se calcula un **intervalo de confianza del 90 %**, que se muestra en pantalla y alimenta la penalización por incertidumbre.

Proveedor (ejemplo)	Servicios en el corredor	Retrasos	Tasa observada	P(tarde) bayesiana	Intervalo 90 %
A	120	30	25,0 %	23,6 %	17,9 % – 29,7 %
B	95	6	6,3 %	7,8 %	4,2 % – 12,3 %
C	5	2	40,0 %	20,0 %	8,6 % – 34,2 %

El proveedor C ilustra el punto: su tasa observada (40 %) se basa en 5 servicios, así que el sistema no la toma al pie de la letra, pero sí marca que su intervalo es muy ancho.

5.5 Mejora o deterioro: decaimiento temporal

Cada servicio pesa según su antigüedad, con una vida media de 30 días, elegida en el backtest (un servicio de hace un mes pesa la mitad que uno de hoy). Así, si un proveedor empieza a fallar, su puntaje baja en días y no en meses; y si mejora, recupera su lugar. La tendencia reciente se muestra como alerta en la recomendación y en la ficha del proveedor.

5.6 Paso 3: costo total esperado

Para cada proveedor factible se calcula un solo número en pesos. Todos los componentes son visibles en pantalla.

```
Costo total esperado = Precio
                     + P(tarde) × Costo del retraso según el nivel
                     + P(incidente) × Costo de un incidente
                     + λ × Ancho del intervalo 90 % de P(tarde) × Costo del retraso
                     + Penalización por concentración

Margen esperado = Tarifa al cliente − Costo total esperado
```

Componente	Qué representa	Factores del reto que cubre
Precio	Tarifa del proveedor para el corredor y el vehículo.	Precio
Retraso esperado	Probabilidad de llegar tarde por lo que cuesta un retraso en ese nivel.	Confiabilidad, tránsito, desempeño, fortalezas y debilidades
Incidente esperado	Probabilidad de daño, robo o cancelación por su costo.	Desempeño histórico
Incertidumbre	Castiga la falta de evidencia: pocos servicios implican un intervalo ancho.	Representatividad del historial
Concentración	Penalización configurable si el proveedor supera un umbral de participación (por ejemplo, 35 % del volumen del mes).	Riesgo de concentración

Además, si el **P90 del tránsito supera el plazo**, el proveedor recibe una alerta de plazo en riesgo; y si ningún proveedor cumple el plazo con 90 % de confianza, la solicitud se escala.

5.7 Ejemplo numérico

Contenedor de 40 pies, Buenaventura → Bogotá, carga general. Proveedores A, B y C como en 5.4. Precios: A $3.850.000, B $4.300.000, C $3.600.000. Tasa de incidentes: A 1,5 %, B 0,5 %, C sin datos (se usa la tasa base de 1 %). Costo de un incidente: $8.000.000. λ = 1. B supera el umbral de concentración (penalización de $100.000). **Cifras ilustrativas.**

Nivel	Proveedor	Precio	Retraso esperado	Incidente	Incertidumbre	Concentración	Costo total
Flexible	**1. C**	**3.600.000**	**60.000**	**80.000**	**76.777**	**0**	**3.816.777**
	2. A	3.850.000	70.714	120.000	35.248	0	4.075.962
	3. B	4.300.000	23.478	40.000	24.376	100.000	4.487.854
Estándar	**1. C**	**3.600.000**	**500.000**	**80.000**	**639.805**	**0**	**4.819.805**

Nivel	Proveedor	Precio	Retraso esperado	Incidente	Incertidumbre	Concentración	Costo total
	2. B	4.300.000	195.652	40.000	203.135	100.000	4.838.787
	3. A	3.850.000	589.286	120.000	293.734	0	4.853.020
Urgente	**1. B**	**4.300.000**	**469.565**	**40.000**	**487.524**	**100.000**	**5.397.089**
	2. A	3.850.000	1.414.286	120.000	704.961	0	6.089.247
	3. C	3.600.000	1.200.000	80.000	1.535.532	0	6.415.532

Flexible → C

Un retraso casi no cuesta dentro de la ventana, así que gana el más barato aunque tenga poca historia. De paso, el sistema aprende sobre C con un riesgo bajo.

Estándar → empate técnico

Los tres quedan a menos de 1 % de diferencia. El sistema **no finge certeza**: activa la revisión detallada y muestra que C es barato pero con solo 5 servicios, y que B es confiable pero concentra volumen.

Urgente → B

Cuando un retraso cuesta $6.000.000, la confiabilidad de B vale mucho más que su sobreprecio. La ventaja sobre A es de unos $700.000 en costo esperado.

5.8 Reglas de revisión y escalamiento

Situación	Qué pasa
Confianza alta, nivel Flexible o Estándar	Aprobación en un clic, viendo el Top-3, la explicación y las alertas.
Nivel Urgente · confianza baja · Top-1 y Top-2 con menos de 3 % de diferencia · sin opción ideal · carga de alto valor	Revisión detallada obligatoria del Top-3.
Margen esperado negativo · ningún proveedor cumple el plazo con 90 % de confianza	Escalamiento a gerencia: aprueba la excepción o renegocia tarifa o plazo.
La persona elige otro proveedor	Motivo obligatorio en un clic (lista desplegable). Alimenta el aprendizaje y la auditoría.

Siempre decide una persona, como exige el reto. Lo que cambia es cuánto esfuerzo le toma: segundos en los casos claros y atención completa donde hay riesgo.

5.9 Ranking determinista y exploración controlada

El reto pide decisiones **consistentes**: la misma solicitud con los mismos datos debe producir siempre el mismo Top-3. Por eso el ranking no usa azar. Pero hay un problema real: si un proveedor nuevo nunca recibe servicios, nunca se sabe si es bueno. La solución es separar las dos cosas:

- El **ranking** usa la estimación bayesiana y es determinista.
- La **exploración** aparece aparte como "sugerencia de prueba": *"el proveedor X tiene pocos datos en este corredor; asignarle este servicio de bajo riesgo ayudaría a evaluarlo"*. Solo en servicios Flexible de bajo riesgo, nunca en Urgente, y la persona decide si la acepta.

5.10 Cómo se presenta la recomendación

Pantalla de ejemplo para el caso Estándar de 5.7. Muestra los siete factores por proveedor, el costo esperado con su desglose, las alertas y los descartados.

Recomendador · Solicitud #10482 — Modelo v1.3 · pesos v1.1

Buenaventura → Bogotá · contenedor 40' · carga general · cargue 24/10 08:00 · plazo 48 h · **Estándar**

⚠ **Empate técnico: Top-1 y Top-2 a 0,4 % de diferencia → revisión detallada recomendada**

#	Proveedor	Precio	Tránsito P50 / P90	Vehículo	Capacidad	P(a tiempo)	Desempeño	Fortaleza / debilidad	Costo esperado
1	**C**	$3,60 M	22 h / 40 h	✓	2 unid.	80 % 5 serv.	Sin incidentes registrados	Más barato · **historial muy corto**	**$4,82 M**
2	**B**	$4,30 M	24 h / 30 h	✓	1 unid.	92 % 95 serv.	💎 Diamante en el corredor	Muy estable · **concentra 41 % del volumen**	$4,84 M
3	**A**	$3,85 M	26 h / 38 h	✓	3 unid.	76 % 120 serv.	Incidentes 1,5 %	Buena capacidad · **débil en temporada de lluvias**	$4,85 M

Descartados: D (sin capacidad para el 24/10) · E (no cubre el corredor Pacífico). **Sugerencia de prueba:** no aplica en Estándar con empate. [Aprobar #1] [Elegir otro + motivo]

Valores ilustrativos. Los factores clave de cada predicción (SHAP) se despliegan al hacer clic en cada proveedor, por ejemplo: *"la puntualidad de A en este corredor es 9 puntos menor que su promedio general"*.

ENTREGABLE · RANKING Y ANÁLISIS DE FORTALEZAS Y DEBILIDADES

6. Ranking, fortalezas, debilidades y riesgos

Índice de Dureza

Para comunicar el desempeño de forma memorable usamos una escala inspirada en la dureza de los minerales: un proveedor "duro" resiste la presión (corredores difíciles, temporada de lluvias, picos de demanda) sin fallar. Se calcula **por corredor y tipo de carga**, porque un proveedor puede ser excelente en el Caribe y débil en el Pacífico.

```
Dureza (0–10) = 10 × [ 0,50 × límite inferior del IC de puntualidad
                     + 0,20 × (1 − variabilidad normalizada del tránsito)
                     + 0,15 × (1 − tasa de incidentes normalizada)
                     + 0,15 × (1 − tasa de rechazo de órdenes) ]
```

Pesos iniciales propuestos, a calibrar con los datos. Usar el límite inferior del intervalo hace que un proveedor con pocos servicios no pueda llegar a Diamante: su dureza aún no está certificada.

Banda	Dureza	Lectura	Uso sugerido
💎 **Diamante**	≥ 9	Confiable incluso en condiciones difíciles.	Urgentes y respaldo.

Banda	Dureza	Lectura	Uso sugerido
🔷 **Zafiro**	7 – 9	Confiable en condiciones normales.	Estándar.
🔹 **Cuarzo**	5 – 7	Cumple con variabilidad.	Flexible; vigilar.
○ **Yeso**	< 5	Se “raya” con facilidad.	Solo Flexible de bajo riesgo; plan de mejora.

El Índice de Dureza sirve para el ranking general, las fichas y la negociación. **La recomendación de cada envío no usa la Dureza**: usa el costo total esperado, que es específico de la solicitud.

Ficha por proveedor

Cada proveedor tiene una ficha generada automáticamente a partir de los datos:

- **Fortalezas:** corredores, tipos de carga o vehículos donde su puntualidad está claramente por encima de su propio promedio y del mercado (con suficiente evidencia).
- **Debilidades:** donde está claramente por debajo; por ejemplo, “puntualidad 18 puntos menor en temporada de lluvias en Buenaventura–Bogotá”.
- **Tendencia:** evolución de la puntualidad con su banda de confianza y alerta si cae de forma sostenida.
- **Riesgos:** señales activas (lista siguiente).

Señales de riesgo para un envío

- Puntualidad en caída en los últimos 30 días.
- P90 del tránsito por encima del plazo.
- Alta variabilidad de tiempos en el corredor.
- Pocos servicios en el corredor o el tipo de carga.
- Utilización de su capacidad cercana al 100 %.
- Rechazos de órdenes recientes.
- Incidentes recientes (daños, robos, novedades graves).
- Concentración del volumen por encima del umbral.

Concentración

Se mide con el índice Herfindahl-Hirschman sobre la participación de cada proveedor en el volumen del periodo: **HHI = Σ (participación)²**. Un HHI mayor a 0,25, o un proveedor por encima del 35 % del volumen, genera alerta para gerencia y activa la penalización por concentración. Así se reduce el riesgo de que un solo proveedor deje sin servicio a la operación.

CALIDAD DE LA RECOMENDACIÓN EN CASOS SIN OPCIÓN IDEAL

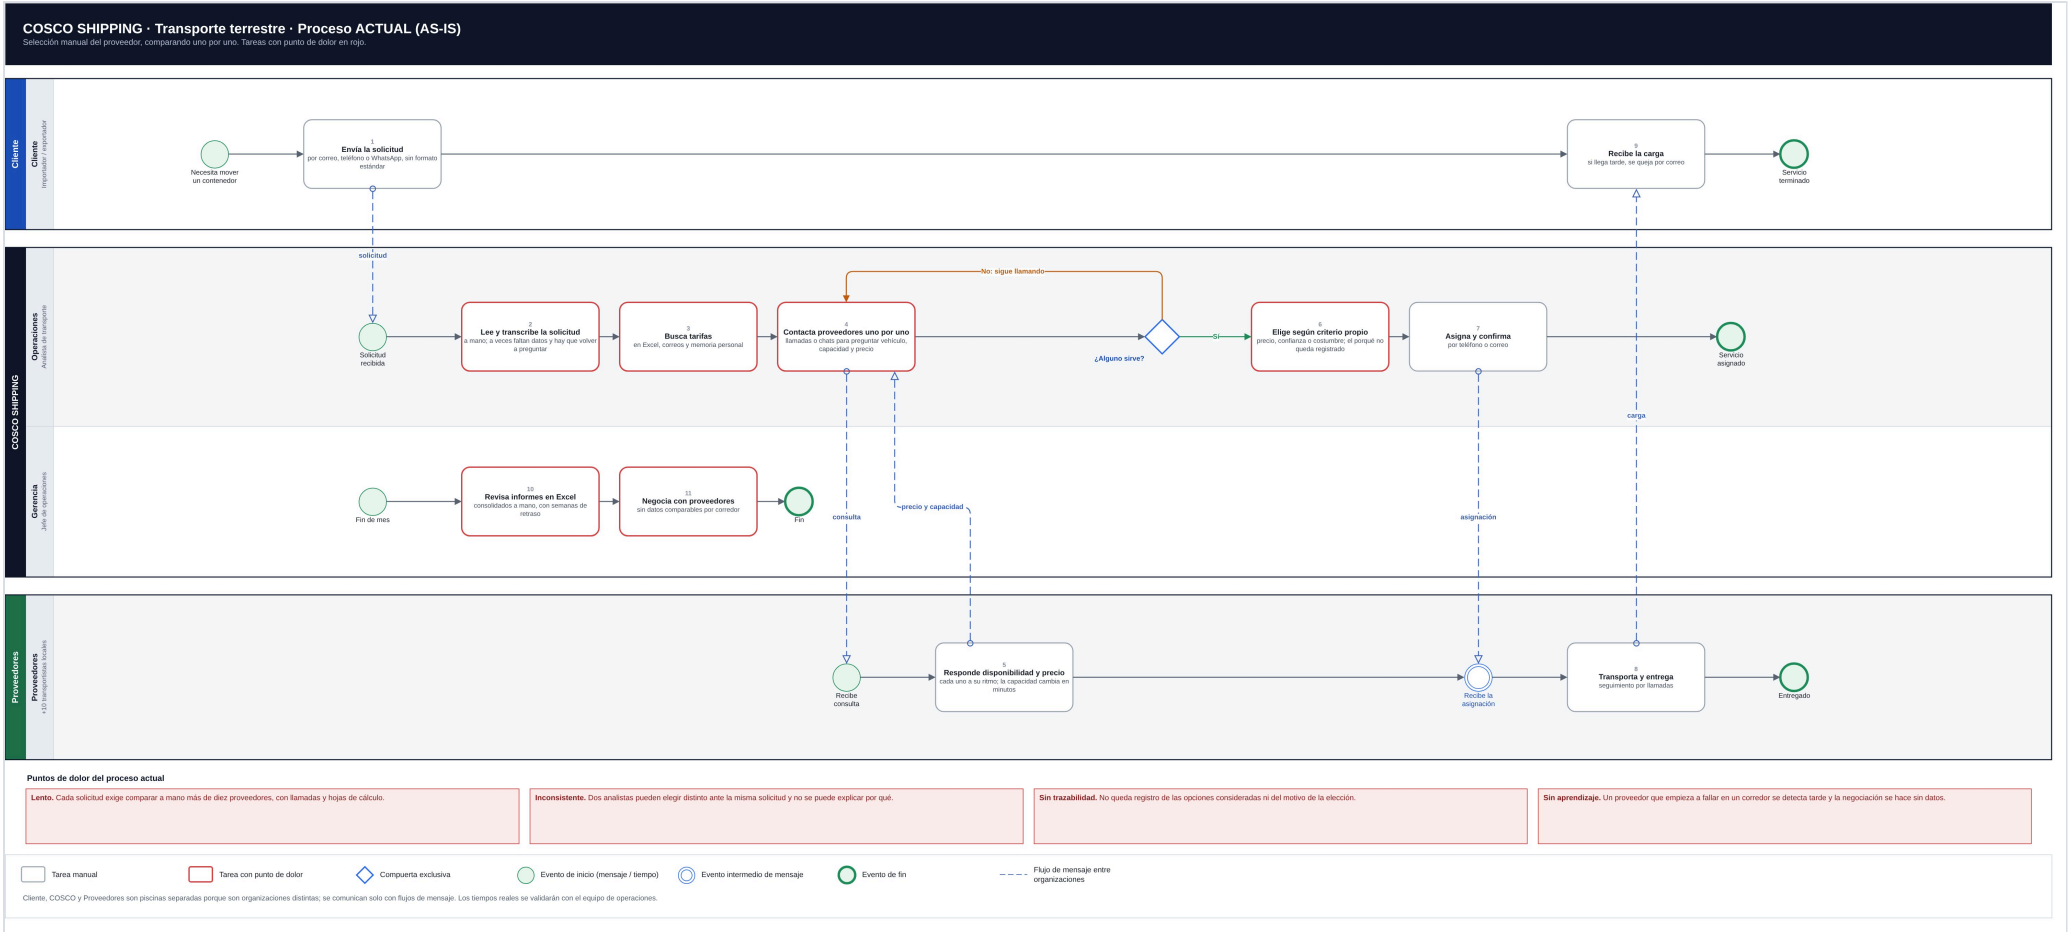
7. Casos difíciles y cómo se resuelven

Caso	Respuesta del sistema
Ningún proveedor tiene el vehículo	Relajación escalonada y explícita: vehículo alterno compatible → dividir la carga → mover la fecha. Se marca “sin opción ideal” y pasa a revisión detallada.
Todos sin capacidad	Muestra cuándo se libera capacidad y ofrece una lista de espera ordenada; si no hay alternativa, gerencia gestiona la excepción (nueva fecha o servicio spot).
Plazo imposible	Si el P90 de todos supera el plazo: alerta temprana con la mejor probabilidad disponible, para avisar al cliente antes y no después.

Caso	Respuesta del sistema
Proveedor nuevo sin historial	Creencia previa del promedio de proveedores similares, etiqueta “datos insuficientes”, penalización por incertidumbre y posibilidad de sugerencia de prueba en servicios de bajo riesgo.
Corredor nunca servido	Se usan corredores similares (misma región y distancia) como referencia, con baja confianza declarada y revisión detallada.
Proveedor en deterioro	El decaimiento temporal lo baja en días; alerta de tendencia aunque su promedio histórico siga siendo bueno.
Empate técnico	Diferencia menor a 3 %: se presentan como equivalentes y se activa la revisión detallada (ejemplo de 5.7).
Proveedor rechaza la orden	Reasignación automática al siguiente del ranking; el rechazo queda en su historial.
Riesgo de retraso en ruta	El monitoreo recalcula la probabilidad de retraso con el GPS; si sube, alerta y propone activar el respaldo antes de que el cliente lo note.
Carga peligrosa o refrigerada	Filtro duro por certificación y vehículo; nunca se compensa con un buen puntaje.
Datos sucios o incompletos	Reglas de limpieza, indicador de calidad de datos y advertencia explícita en la recomendación.
Capacidad desactualizada	Si el último reporte tiene más de N horas, se muestra “capacidad no confirmada” y la orden exige confirmación del proveedor.
Dos solicitudes compiten por la misma capacidad	Se asignan en conjunto (problema de asignación) priorizando nivel de servicio, holgura del plazo y valor del cliente. Funcionalidad opcional.

COMPRENSIÓN DEL PROBLEMA · PROCESO ACTUAL

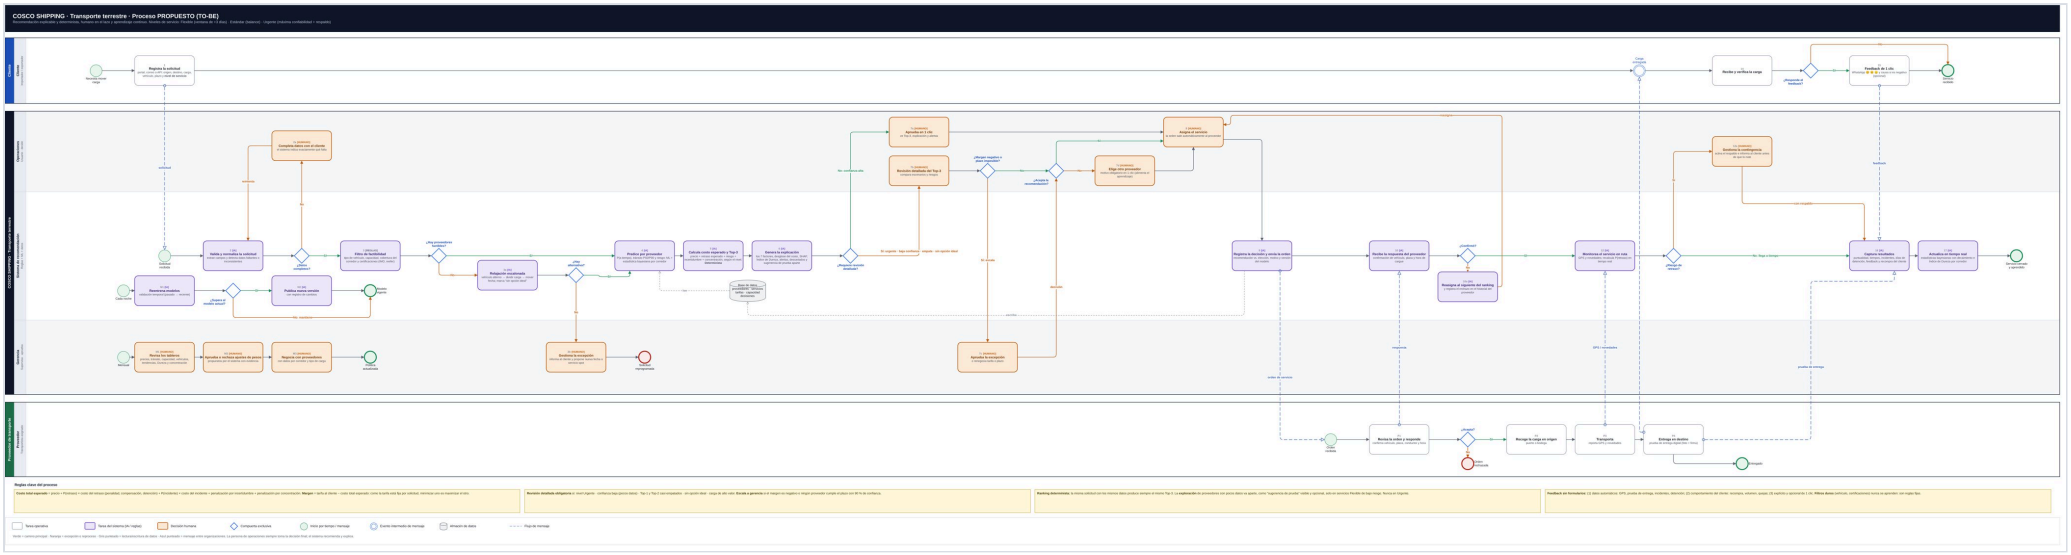
8. Procesos · AS-IS: cómo se decide hoy



Cliente, COSCO y Proveedores aparecen como piscinas separadas porque son organizaciones distintas; se comunican solo con flujos de mensaje (líneas azules punteadas).

PROCESO PROPUESTO · VISTA GENERAL

TO-BE: el proceso con el sistema



Vista completa. Las páginas siguientes muestran cada fase ampliada. Morado: tareas del sistema · Naranja: decisiones humanas · Blanco: tareas operativas.

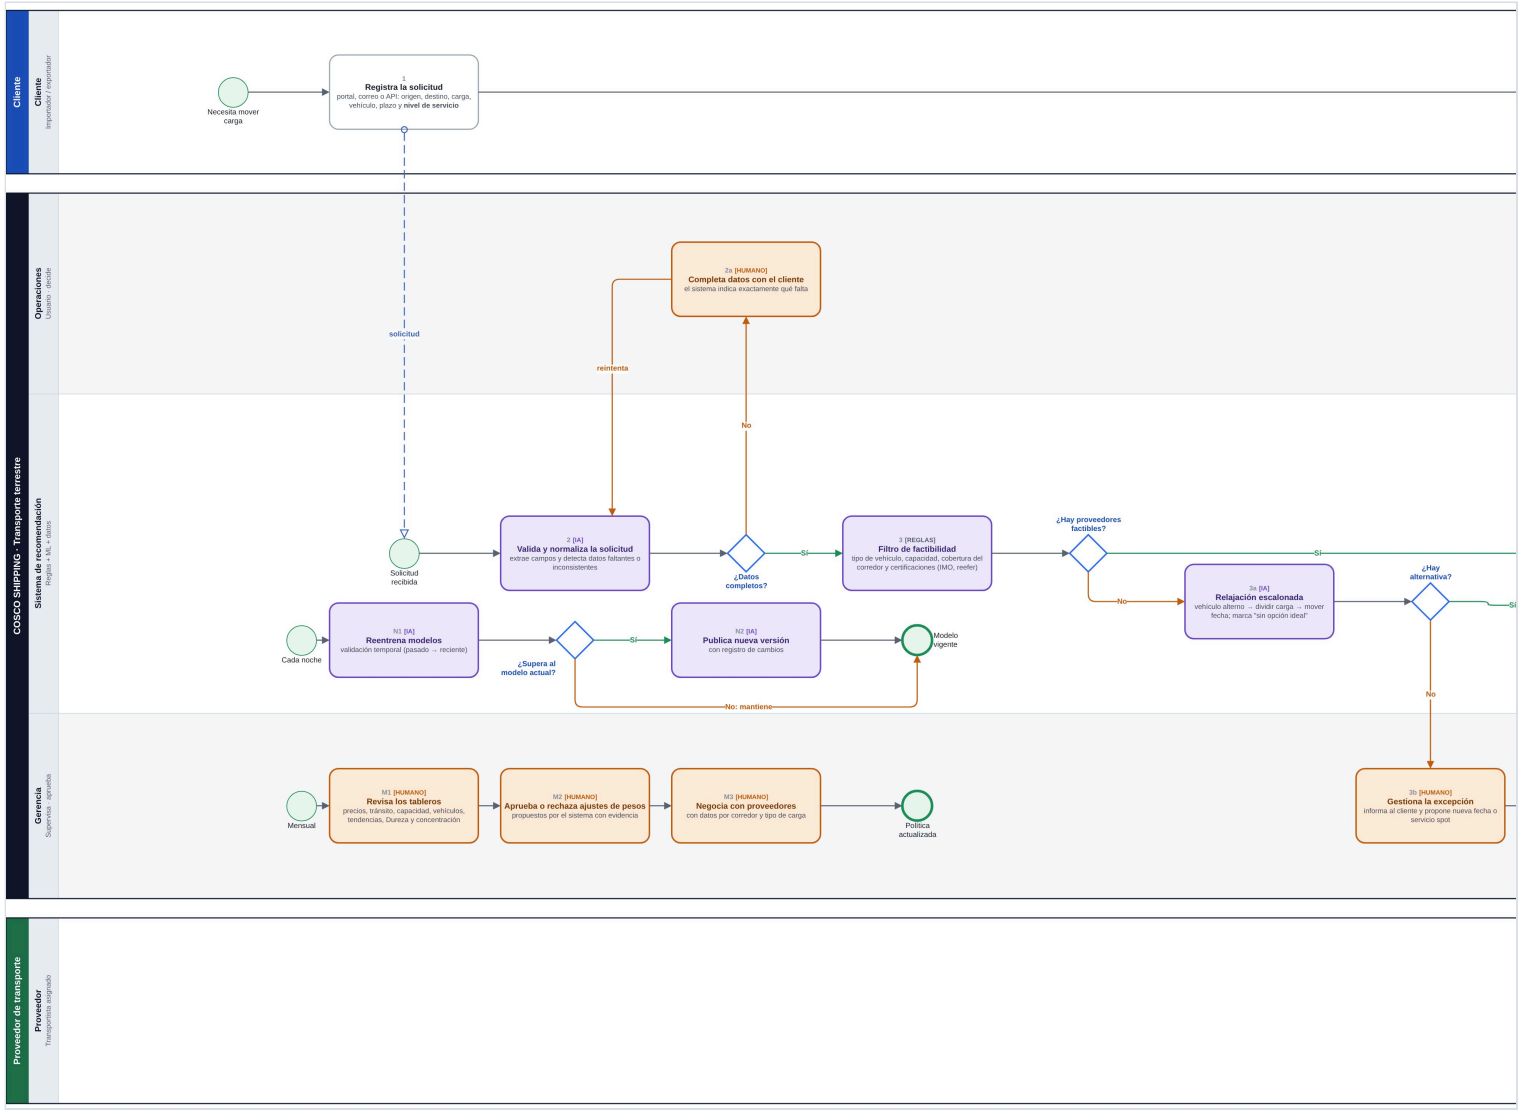
Cuatro fases

1. Recepción y factibilidad · **2. Recomendación y decisión** · **3. Asignación y ejecución** · **4. Cierre y aprendizaje**. Además, dos ciclos periódicos: reentrenamiento nocturno de modelos y revisión mensual de gerencia.

Reglas clave

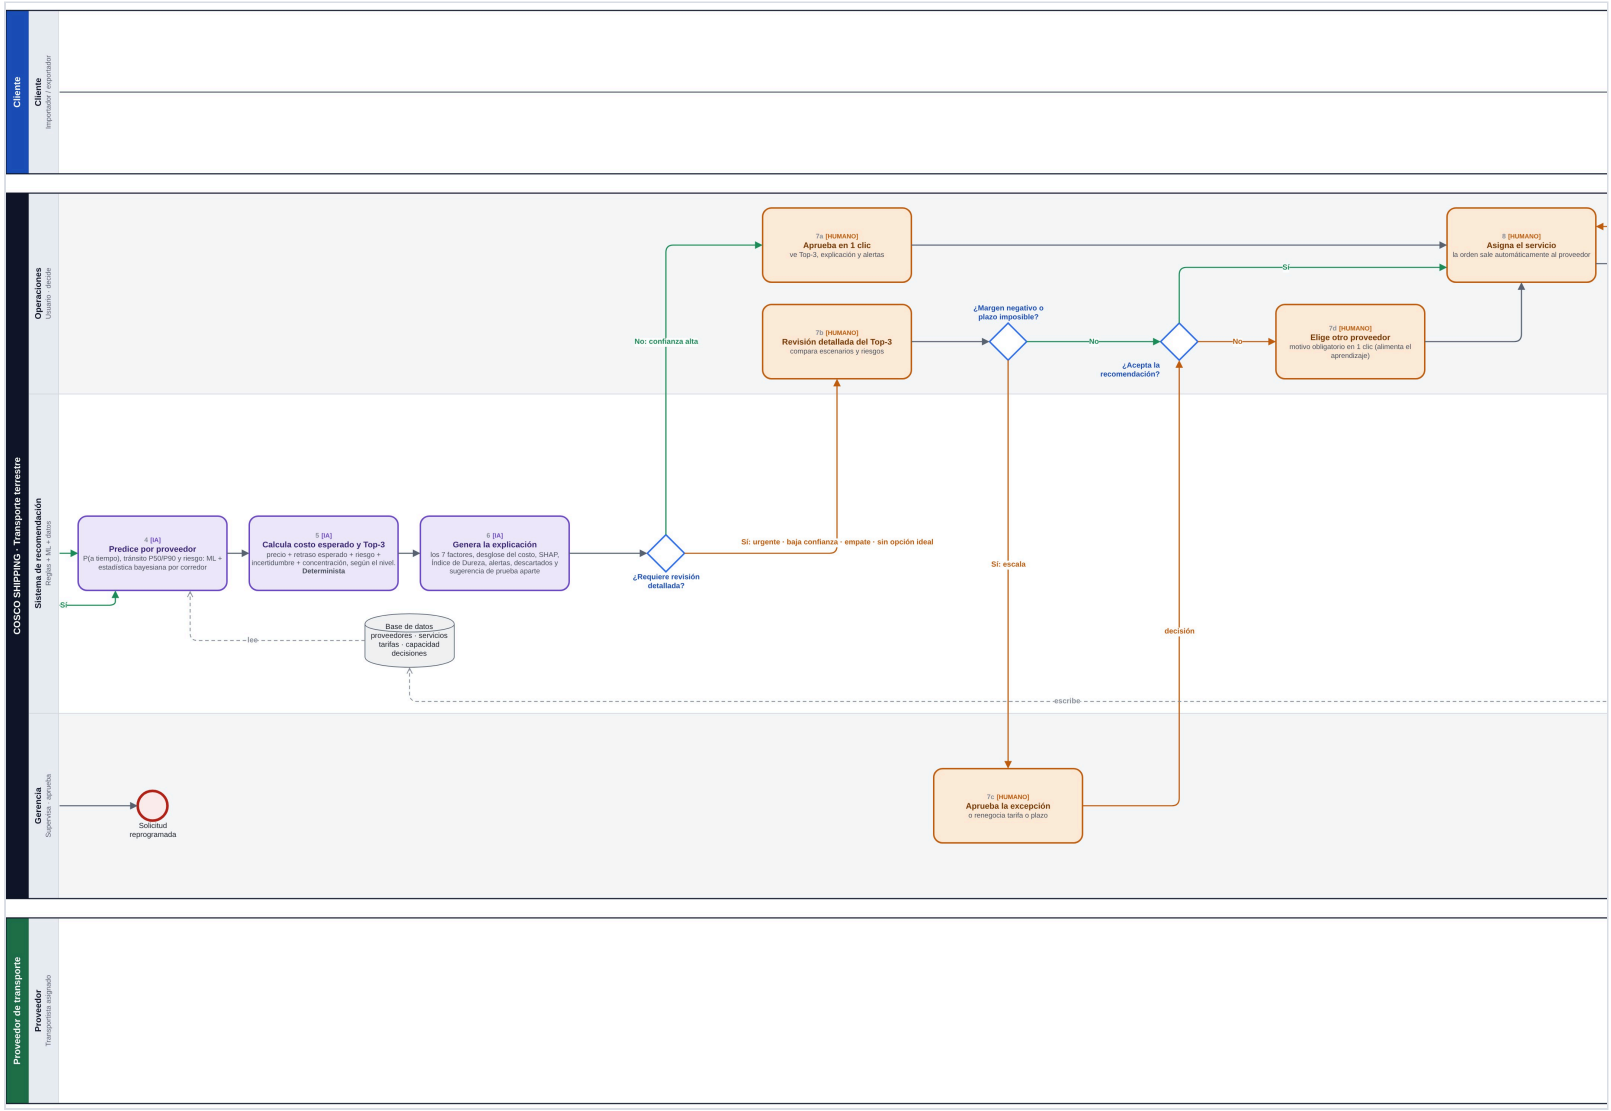
Ranking determinista; exploración aparte y opcional; filtros duros fijos; revisión detallada en casos de riesgo; escalamiento a gerencia con margen negativo o plazo imposible.

Fase 1 · Recepción y factibilidad



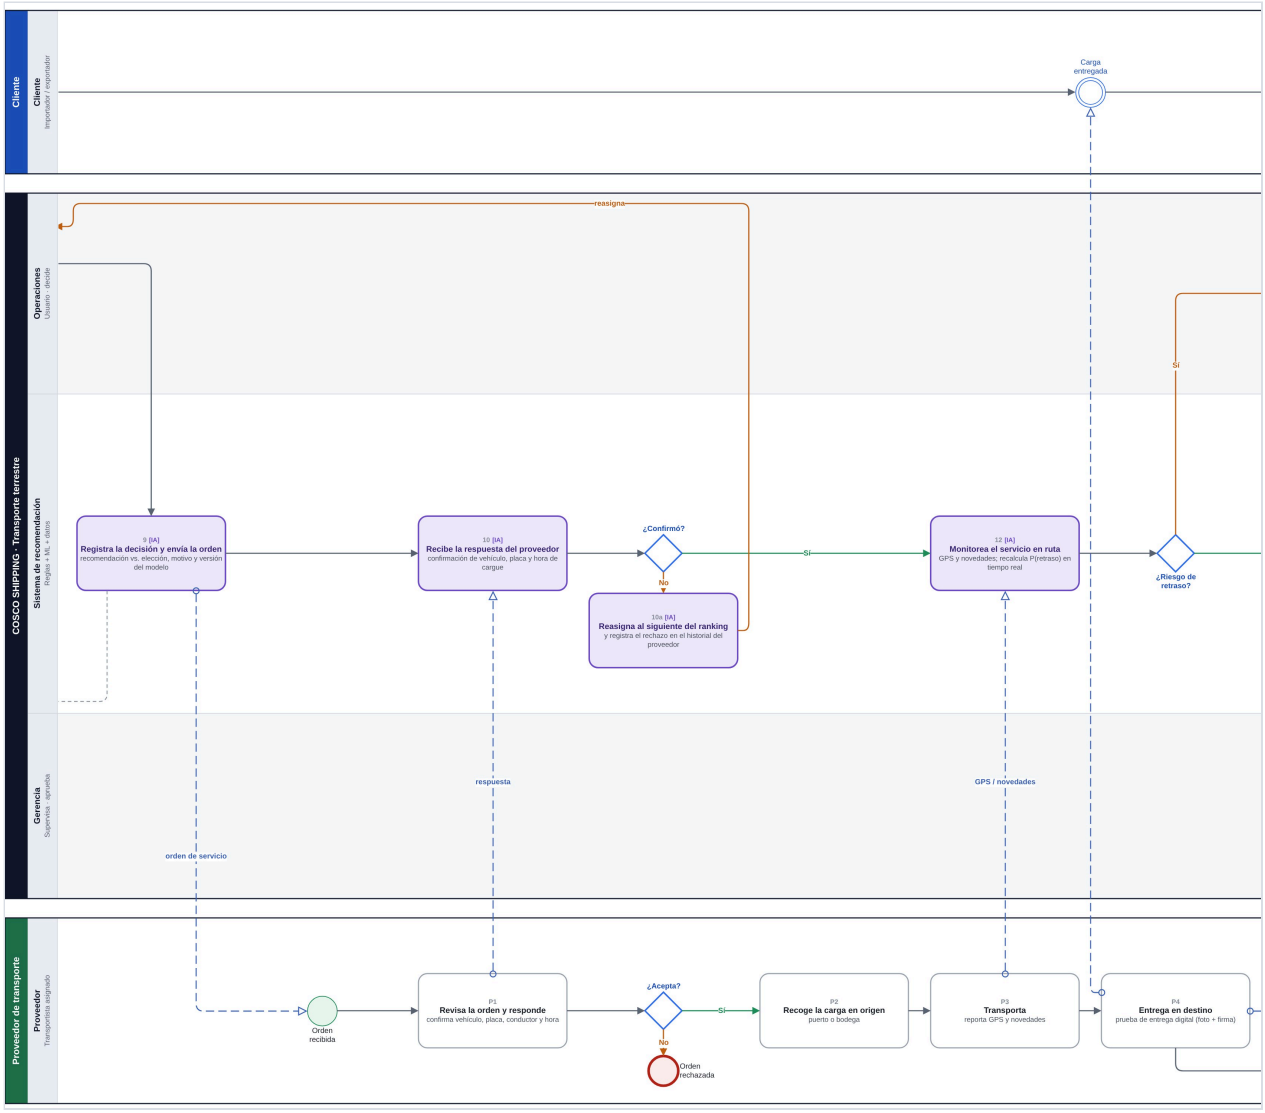
El cliente registra la solicitud con su nivel de servicio (1). El sistema la valida (2) y, si faltan datos, operaciones los completa con el cliente (2a). El filtro de factibilidad (3) descarta a quien no puede hacer el servicio. Si nadie cumple, se intenta la relajación escalonada (3a) y, si tampoco hay alternativa, gerencia gestiona la excepción (3b). De noche corre el reentrenamiento (N1–N2) y cada mes gerencia revisa tableros, aprueba ajustes de pesos y negocia (M1–M3).

Fase 2 · Recomendación y decisión



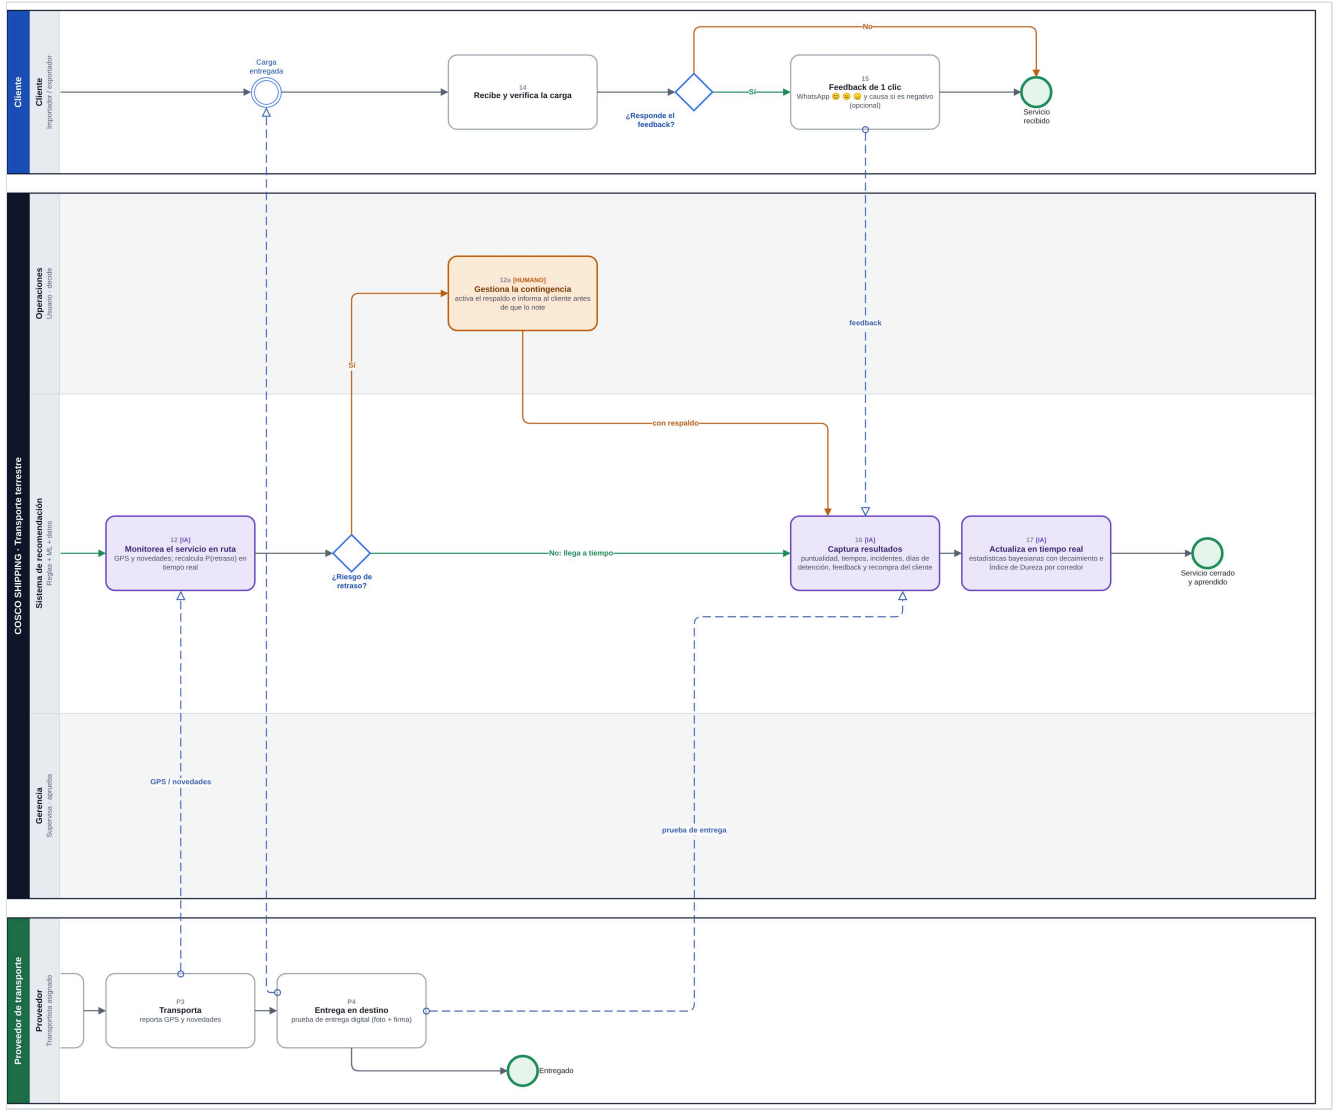
El sistema predice (4), calcula el costo esperado y el Top-3 de forma determinista (5) y genera la explicación (6). Si la confianza es alta, operaciones aprueba en un clic (7a); si no, hace revisión detallada (7b). Con margen negativo o plazo imposible, gerencia aprueba la excepción (7c). Si la persona elige otro proveedor, registra el motivo (7d). Luego asigna el servicio (8).

Fase 3 · Asignación y ejecución



El sistema registra la decisión y envía la orden (9). El proveedor la revisa y responde (P1). Si rechaza, el sistema reasigna al siguiente del ranking (10a). Si acepta, recoge la carga (P2) y la transporta reportando GPS y novedades (P3), que el sistema monitorea en tiempo real (12).

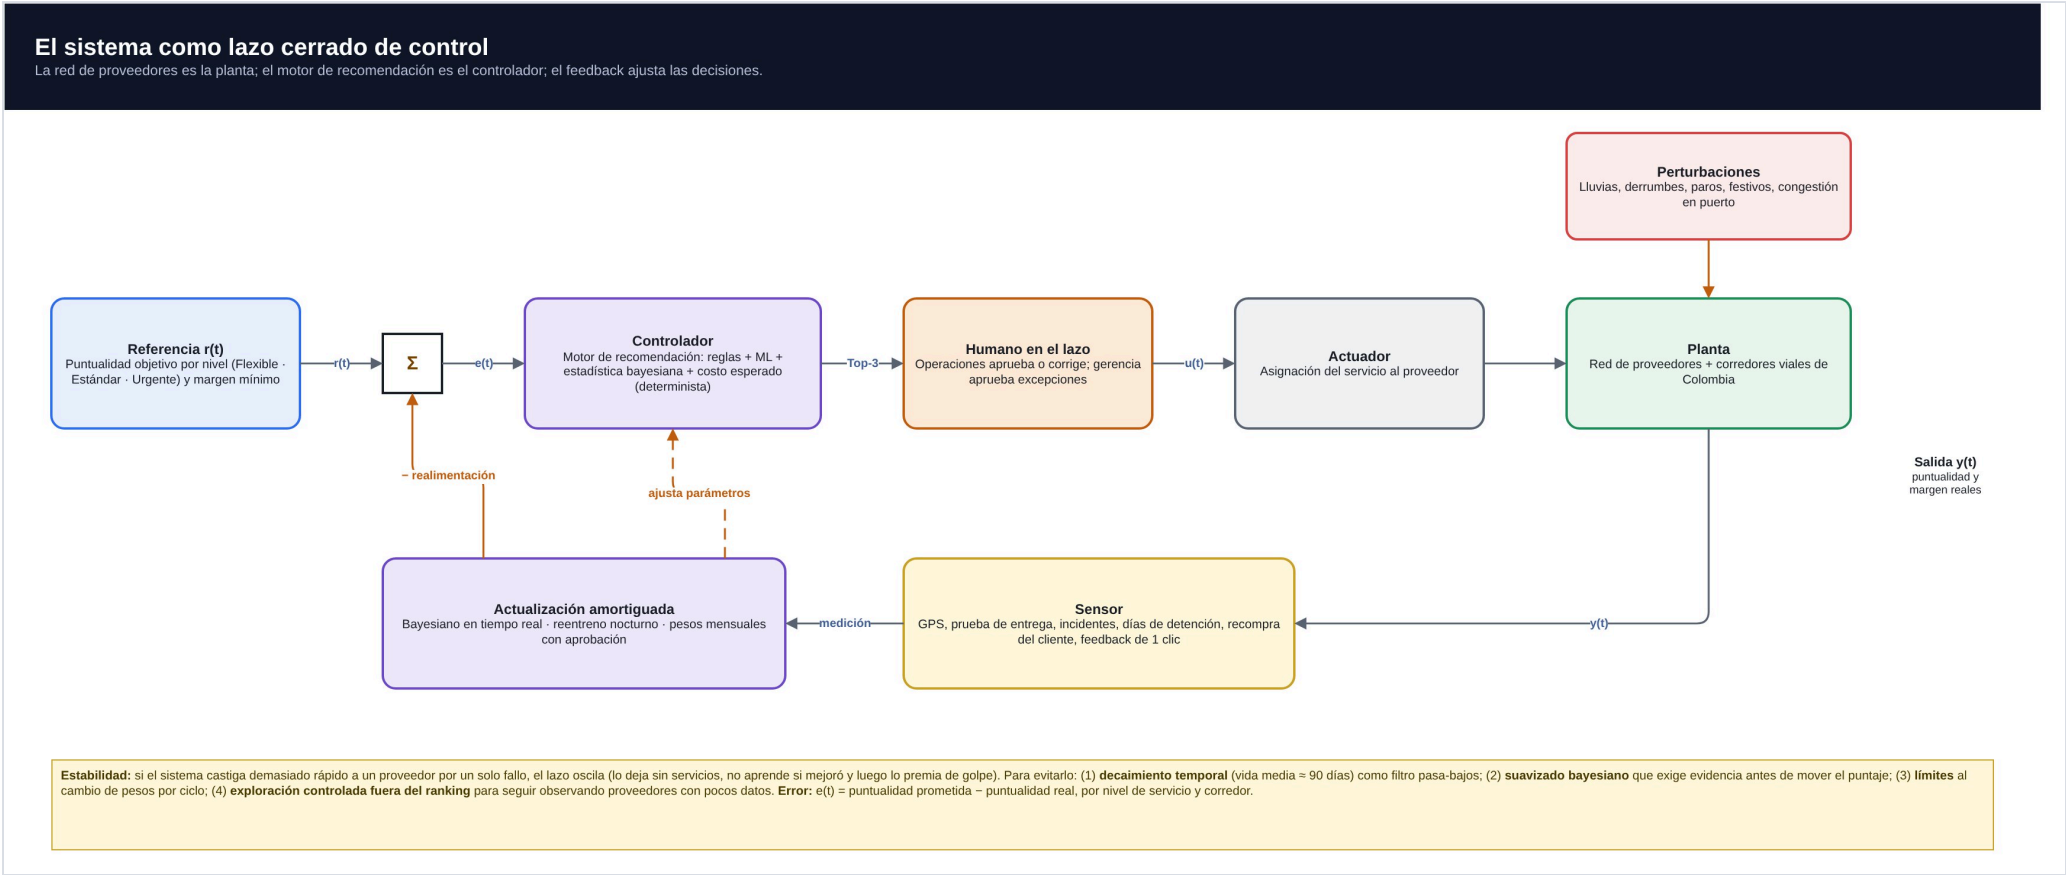
Fase 4 · Cierre y aprendizaje



Si hay riesgo de retraso, operaciones gestiona la contingencia (12a). El proveedor entrega con prueba digital (P4); el cliente recibe y, si quiere, deja un feedback de un clic (14–15). El sistema captura los resultados (16) y actualiza en tiempo real las estadísticas e Índice de Dureza (17).

APORTE DE INGENIERÍA DE CONTROL

El sistema como lazo cerrado de control



La referencia es la puntualidad prometida por nivel; el error es la diferencia con la puntualidad real. El decaimiento temporal, el suavizado bayesiano y los límites al cambio de pesos actúan como amortiguamiento para que el lazo no oscile.

DESEMPEÑO QUE CAMBIA EN EL TIEMPO

9. Aprendizaje continuo y retroalimentación

Tres velocidades de aprendizaje

Qué se actualiza	Cuándo	Cómo y por qué así
Estadísticas del proveedor (puntualidad, tiempos, Dureza)	Al cerrar cada servicio	Actualización bayesiana: sumar la evidencia nueva. Es barata, estable y explicable; el ranking reacciona en tiempo real.
Modelos de ML (M1–M4)	Cada noche	Reentrenamiento con validación temporal; el modelo nuevo solo reemplaza al actual si es igual o mejor en los datos recientes.
Pesos de la función de decisión	Mensual, con aprobación	El sistema propone ajustes con evidencia; gerencia los aprueba. Cambios con límites por ciclo.

No se reentrena el modelo con cada dato porque un solo evento extremo (un derrumbe, por ejemplo) lo movería de golpe, sería imposible explicar por qué cambió una recomendación entre una hora y otra, y una empresa grande necesita saber qué versión tomó cada decisión.

Retroalimentación sin formularios

Los clientes de COSCO son empresas importadoras y exportadoras; su opinión se ve más en su comportamiento que en encuestas. Por eso hay tres capas:

1 · Automática
Hora real de entrega, retrasos, incidentes, reclamaciones, días de detención del contenedor, GPS y prueba de entrega. No le pide nada a nadie.

2 · Comportamiento
¿El cliente volvió a pedir? ¿Su volumen sube o baja? ¿Abrió quejas o renegoció la tarifa? Es feedback implícito.

3 · Explícita, de 1 clic
WhatsApp con tres caritas y la causa si es negativa (proveedor, cliente, puerto, clima), enviado a una muestra de servicios. Además, el motivo obligatorio del operador cuando no acepta la recomendación.

Las calificaciones explícitas se tratan con cuidado: se usan promedios bayesianos, se normalizan por evaluador y no se castiga al proveedor por retrasos con causa ajena (aduana, puerto).

Ajuste de pesos a partir de las decisiones humanas

Cada vez que la persona elige un proveedor distinto al recomendado se genera una preferencia (“B por encima de A en este contexto”). Con esos pares se estima un modelo de preferencias (regresión logística sobre la diferencia de variables, tipo Bradley-Terry) que sugiere ajustes como “en carga refrigerada, los operadores valoran la puntualidad 1,4 veces más de lo asumido”. El ajuste solo se propone si las elecciones humanas también tuvieron **mejores resultados reales**; así el sistema aprende de los aciertos y no copia los sesgos.

Salvaguardas

- Los filtros duros nunca se aprenden.
- Ningún peso cambia más de un porcentaje fijo por ciclo.
- Cada recomendación guarda la versión del modelo y de los pesos.

- Monitoreo de deriva: si la puntualidad real se separa de la predicha, se genera alerta.
- Detección de calificaciones anómalas (por ejemplo, muchas notas perfectas de un mismo cliente vinculado a un proveedor).

ENTREGABLE · TABLEROS VISUALES

10. Tableros visuales

El enunciado pide tableros de **precios, tiempos de tránsito, capacidad, disponibilidad de vehículos y tendencias de desempeño**. Los cinco están cubiertos, junto con el ranking y los indicadores de gerencia.

Tablero	Usuario	Preguntas que responde	Visualizaciones
Precios	Operaciones, gerencia	¿Quién es caro o barato en cada corredor? ¿Pagamos sobreprecio por confiabilidad real?	Mapa de calor proveedor × corredor (índice de precio); dispersión precio vs. puntualidad.
Tiempos de tránsito	Operaciones	¿Cuánto tarda cada proveedor y qué tan variable es?	Cajas y bigotes por proveedor y corredor; P50 y P90 frente al plazo típico.
Capacidad	Operaciones	¿Quién tiene capacidad esta semana y qué tan cargado está?	Barras de unidades disponibles por proveedor y fecha; utilización en %.
Disponibilidad de vehículos	Operaciones, gerencia	¿Qué tipos de vehículo escasean? ¿Dónde dependemos de un solo proveedor?	Matriz proveedor × tipo de vehículo; alertas de tipos con un solo proveedor.
Tendencias de desempeño	Gerencia	¿Quién mejora o empeora? ¿Desde cuándo?	Líneas de puntualidad con banda de confianza; alertas de deterioro.
Ranking y fichas	Gerencia, compras	¿Cómo se comparan los proveedores y qué riesgos tiene cada uno?	Ranking por Índice de Dureza por corredor; ficha con fortalezas, debilidades y riesgos.
Gestión del sistema	Gerencia	¿Cuánto ahorramos? ¿Qué tanto se acepta la recomendación? ¿Estamos concentrados?	HHI y participación por proveedor; tasa de aceptación; motivos de rechazo; costo esperado vs. real.

La interfaz del operador (recomendador) y los tableros leen la misma base de datos. Los tableros pueden construirse en la misma aplicación web o en Power BI conectado a esa base; la segunda opción facilita la adopción en una empresa que ya usa esa herramienta.

ENTREGABLE · DEMOSTRACIÓN CON DATOS HISTÓRICOS Y DE PRUEBA

11. Datos para la demostración

> **Datos sintéticos confirmados.** COSCO informó que no entregará datos, así que el equipo los genera con un simulador (descrito abajo) que usa el mismo esquema que tendrían los datos reales. En la presentación se declara que son sintéticos, qué parámetros se tomaron de fuentes (distancias de Buenaventura: 519 km a Bogotá, 165 km a Cali, 499 km a Medellín) y cuáles son supuestos editables. 35 reglas automáticas de calidad validan los datos generados.

Si más adelante hubiera datos reales

1. Mapear las columnas al modelo de datos de la sección 4.
2. Limpiar: duplicados, tiempos imposibles, fechas invertidas, nombres de proveedor inconsistentes, vacíos.
3. Separar históricos (entrenamiento) y fase de prueba (validación y demostración), respetando el orden temporal.
4. Calcular estadísticas, entrenar M1 y M2 y generar el backtest.

Simulador con “verdad oculta”, en vivo y con eventos

En lugar de datos aleatorios, un simulador asigna a cada proveedor parámetros ocultos y genera servicios a partir de ellos:

- Confiabilidad base y fortalezas o debilidades por corredor (por ejemplo, excelente en el Caribe y débil en el Pacífico).
- Nivel de precios, flota por tipo de vehículo y capacidad semanal.
- Historias: un proveedor que se deteriora a mitad de año, uno que mejora, uno nuevo, uno caro pero mediocre.
- Estacionalidad: temporadas de lluvias, festivos y algún paro.
- Corredores reales: Buenaventura, Cartagena, Santa Marta y Barranquilla hacia Bogotá, Medellín, Cali y Bucaramanga, con distancias reales y precios de referencia calibrados con fuentes públicas de costos de transporte de carga (por ejemplo, el sistema de costos del Ministerio de Transporte), a validar.

El simulador también funciona **en vivo**: agrega un día simulado cada pocos segundos (llegan pedidos, se asignan y se cierran con resultados) y permite **inyectar eventos**, como volver poco confiable a un proveedor desde una fecha. En pruebas con siete semillas distintas, un estimador bayesiano detectó el colapso de Andina Cargo (P(tarde) mayor a 15 %) entre 20 y 40 días después de que empezó con vida media de 30 días, entre 26 y 56 días con 45 días, y entre 36 y 68 días (o no lo detectó antes de mediados de octubre) con 90 días; sin decaimiento no lo detectó nunca. La vida media es un compromiso entre detectar pronto y no sobrerreaccionar a eventos puntuales, y se decide con el backtest.

Como el equipo conoce la verdad oculta, puede **demostrar que el sistema la descubre**: por ejemplo, cuántos días tarda en detectar el deterioro de un proveedor y bajarlo en el ranking.

Casos de la demostración

Caso	Qué demuestra	Criterio que respalda
Envío típico, Estándar	Funcionamiento de punta a punta y aprobación en un clic.	Funcionamiento (4)
Mismo envío en Flexible y Urgente	Cómo cambia el ganador según lo que cuesta un retraso.	Calidad de la recomendación (2), metodología (3)
El mejor no tiene capacidad	Descarte con motivo y alternativa explicada.	Casos sin opción ideal (2)
Proveedor nuevo	Suavizado bayesiano, penalización por incertidumbre y sugerencia de prueba.	Metodología (3)
Carga peligrosa	Filtro duro por certificación.	Coherencia con requisitos (2)

Caso	Qué demuestra	Criterio que respalda
Reproducción en vivo	Los datos de prueba se reproducen en orden cronológico; un proveedor se deteriora y el sistema lo detecta.	Visualización (5), aprendizaje

EVIDENCIA DE QUE FUNCIONA

12. Validación

Qué se valida	Cómo	Métrica
Modelos predictivos	División temporal: se entrena con el pasado y se prueba con lo más reciente. Nunca división aleatoria, para evitar fuga de información.	M1: AUC y Brier con curva de calibración. M2: pérdida pinball y cobertura real del P90. M3: error absoluto medio.
Calidad de la recomendación	Backtest: en las decisiones pasadas donde el sistema habría elegido distinto, se compara el resultado real del proveedor elegido con el desempeño esperado del recomendado en servicios comparables.	Diferencia de costo esperado y de puntualidad.
Consistencia	La misma solicitud procesada varias veces con los mismos datos.	100 % de rankings idénticos.
Coherencia con requisitos	Batería de solicitudes con requisitos distintos (vehículo, certificaciones, plazo).	0 recomendaciones que violen un filtro duro.
Detección de cambios	Con el simulador, un deterioro conocido en una fecha conocida.	Días hasta la alerta y hasta el cambio de ranking.
Rapidez	Tiempo desde que llega la solicitud hasta la recomendación.	Segundos por solicitud.

> **Limitación declarada.** En el backtest solo se observa lo que pasó con el proveedor elegido, no con el que no se eligió (sesgo de selección). Por eso la comparación se hace contra el desempeño del recomendado en servicios similares, y el resultado se presenta como estimación, no como certeza.

FLEXIBILIDAD DE LA ARQUITECTURA

13. Motores de decisión intercambiables: nuestro modelo frente a Jev y a un LLM

Existen modelos especializados en decidir, como **Jev**, que son rápidos y muy baratos. En lugar de competir contra ellos, la arquitectura los trata como **motores intercambiables**: se conectan al mismo contrato de entrada y salida (sección 16), se miden con las mismas solicitudes y se elige por evidencia.

13.1 Qué es Jev, según las fuentes públicas

Aspecto	Lo que se sabe
Qué es	Modelo de TypeSafe AI lanzado en septiembre de 2026. La empresa dice que no es un LLM sino un modelo "System One": no escribe texto, **elige entre opciones definidas por el usuario**.
Cómo se usa	Se envía un *estado* (texto o JSON) y preguntas tipadas: *Choice* (elegir una de hasta 255 opciones), *Score* (puntuar contra una rúbrica ordenada) y *Noul* (probabilidad entre 0 y 1). Devuelve la respuesta, probabilidades y una confianza.
Precio	US$ 0,042 por millón de tokens de entrada; la salida no se cobra. Una solicitud de ~1.000 tokens cuesta unos US$ 0,000042.
Velocidad	El proveedor indica entre 70 y 500 ms por llamada. Son cifras propias; no hay mediciones independientes.
Límites	No explica su razonamiento, no es calculadora (aritmética, conteos y fechas deben hacerse en código), pierde precisión con texto irrelevante en la entrada, y una respuesta bien formada puede ser incorrecta. No se publican resultados de benchmarks.
Acceso	API de TypeSafe y pasarelas de terceros. Las fuentes consultadas no indican si los pesos son públicos ni si el cliente puede reentrenarlo; se personaliza con la redacción de las preguntas y las opciones.

> **¿Es una caja negra?** Para nuestro uso, sí en lo esencial: entrega la opción elegida, probabilidades y una confianza, pero **no las razones**; su arquitectura y su entrenamiento (RLCD, según el proveedor) no tienen un artículo publicado, y las fuentes no aclaran si dos llamadas idénticas dan siempre el mismo resultado. Por eso no puede ser el único motor en una decisión que debe ser consistente, explicable y auditable.

13.2 Arquitectura con motores conectables

Motor A · Nuestro modelo
IA Reglas duras, bayesiano, M1/M2 y costo esperado. Determinista, explicable al detalle, aprende con cada servicio. Cuesta casi cero por decisión.

Motor B · Jev
IA Decisión tipada rápida y barata. Se usa como **segunda opinión**, desempate o clasificador de urgencia sobre el Top-N que ya calculó A. Caja negra.

Motor C · LLM
IA No decide el ranking. Redacta la explicación en lenguaje natural a partir del desglose y actúa como **juez crítico** que busca contradicciones en la recomendación.

- **Los números los calcula nuestro código.** Jev no es calculadora, así que nunca recibe cálculos por hacer: recibe un estado ya resumido (por proveedor: precio, P(a tiempo), P90, servicios, alertas) con las estadísticas del día.
- **Los datos actualizados llegan en el estado, no en el entrenamiento.** Cada llamada reconstruye el estado con las estadísticas bayesianas al instante; así Jev "ve" la información fresca de las empresas sin reentrenarse. Quien aprende de los resultados sigue siendo nuestro Motor A.
- **Los desacuerdos se vuelven información.** Si A y B eligen distinto, la solicitud pasa a revisión detallada y se registra cuál tuvo razón después; con el tiempo, eso mide qué motor conviene en cada tipo de caso.
- **Los filtros duros siguen siendo reglas.** Ningún motor puede recomendar un proveedor que no pasó la factibilidad.

13.3 Comparación en paralelo

Criterio	A · Nuestro modelo	B · Jev	C · LLM
Transparencia	Total: desglose en pesos y factores clave.	Baja: respuesta, probabilidades y confianza.	Alta en texto, pero la explicación puede no reflejar el cálculo real.
Consistencia	Determinista (misma entrada, misma salida).	No garantizada; fijar la versión del modelo.	No determinista.
Aprende de los resultados	Sí: bayesiano en tiempo real y reentrenamiento nocturno.	No por sí mismo; usa datos frescos en el estado.	No por sí mismo; usa datos frescos en el contexto.
Aritmética y fechas	Exactas.	Débil: se hace en código.	Frágil: se hace en código.
Velocidad	Medida: ~0,02 ms por decisión (12 proveedores, CPU).	70–500 ms según el proveedor, a medir.	Segundos, a medir.
Costo por 1.000 decisiones	≈ 0 (cómputo propio).	≈ US$ 0,04 (precio publicado, ~1.000 tokens por decisión).	Depende del modelo; ver 13.4.
Datos de la empresa	Permanecen en casa.	Se envían a un tercero: tarifas y desempeño de proveedores.	Se envían a un tercero.
Auditoría	Completa, con versión de modelo y pesos.	Limitada a entrada y salida.	Limitada a entrada y salida.
Flexibilidad	Pesos y reglas configurables por el negocio.	Cambia con la redacción de preguntas y opciones.	Cambia con el texto de las instrucciones.

13.4 Costos y posibilidades

Cada solicitud usa unos 1.000 tokens de entrada en Jev (12 proveedores resumidos más la pregunta). Para el LLM se muestra un **precio hipotético** de US$ 3 por millón de tokens de entrada y US$ 15 por millón de salida, con 1.500 tokens de entrada y 400 de salida por decisión (a sustituir por el precio real del modelo elegido).

Decisiones por mes	A · Nuestro modelo	B · Jev (precio publicado)	C · LLM (precio hipotético)
1.000	≈ 0	US$ 0,04	US$ 10,50
100.000	≈ 0	US$ 4,20	US$ 1.050
1.000.000	≈ 0	US$ 42	US$ 10.500

A no tiene costo por llamada, pero sí costos fijos de desarrollo, servidor y mantenimiento de modelos. Para el volumen de COSCO el costo de Jev es insignificante frente al valor de una sola decisión (un retraso urgente cuesta millones de pesos); lo que importa es la precisión y la gobernanza, no el precio.

13.5 Tres modos de operación

Modo	Motores	Cuándo conviene
Económico	A	Operación normal, datos confidenciales, sin dependencia externa.

Modo	Motores	Cuándo conviene
Verificado	A + B (segunda opinión)	Servicios Urgentes, empates técnicos o proveedores con pocos datos: si A y B discrepan, revisión detallada.
Completo	A + B + C (explicación y crítica)	Casos escalados a gerencia o clientes clave: justificación en lenguaje natural y revisión cruzada.

13.6 Resultados medidos hasta ahora

Probamos nuestro motor y tres referencias sobre **6.000 solicitudes simuladas** (12 proveedores, 8 corredores, historiales de 3 a 200 servicios por pareja, tres niveles de servicio). El simulador conoce la probabilidad real de retraso de cada proveedor, así que se puede calcular el **arrepentimiento**: cuánto cuesta, en pesos esperados reales, haber elegido ese proveedor en lugar del mejor posible.

Motor	Arrepentimiento medio por servicio	Elige el óptimo	Tiempo por decisión
Aleatorio	$ 693.572	7,7 %	< 0,01 ms
Siempre el más barato	$ 378.402	21,1 %	< 0,01 ms
Historial crudo (sin suavizar)	$ 253.745	30,1 %	0,01 ms
A · Nuestro (bayesiano + costo esperado)	**$ 65.948**	**61,6 %**	**0,02 ms**
B · Jev	por medir	por medir	por medir
C · LLM	por medir	por medir	por medir

> **Cómo leer esta tabla.** Los datos son simulados con una distribución similar a la que supone nuestro modelo, así que la ventaja de A frente a las referencias probablemente está exagerada respecto a datos reales. Las filas de Jev y del LLM **no tienen cifras** porque aún no se han ejecutado: no se afirmará ninguna ventaja o desventaja de ellos hasta medirla con la misma batería de solicitudes.

13.7 Plan del experimento (para el hackathon)

1. Fijar un conjunto de 500 a 1.000 solicitudes con su resultado conocido (del simulador o de los datos de COSCO).
2. Construir para cada solicitud el estado resumido de proveedores factibles y la pregunta *Choice* para Jev, con la versión del modelo fijada.
3. Ejecutar A, B, C (el LLM solo para explicar y criticar) y las referencias sobre el mismo conjunto.
4. Medir: arrepentimiento, % de acuerdo entre motores, % enviado a revisión, latencia de extremo a extremo (percentiles 50 y 95) y costo en tokens.
5. Probar robustez: cambiar el orden y los nombres de las opciones (Jev es sensible a ellos según estudios citados), agregar proveedores irrelevantes y repetir la misma solicitud varias veces.
6. Mostrar el resultado en un tablero de comparación y declarar qué se midió y qué no.

13.8 Qué decir al jurado

> “Nuestra solución no depende de un solo modelo. El núcleo es transparente y barato; y está construida para conectar motores como Jev o un LLM y **comparar con datos** cuál sirve en cada caso, con costo y velocidad a la vista. COSCO elige el modo según el riesgo del servicio y la sensibilidad de sus datos.” Esta formulación evita prometer una ventaja que todavía no se midió y muestra criterio técnico, flexibilidad y comprensión de costos, que son los criterios de metodología, valor de negocio y viabilidad de la rúbrica.

13.9 Riesgos y puntos por verificar

- **Confidencialidad:** enviar tarifas y desempeño de proveedores a un tercero requiere autorización de COSCO; en el modo Económico no sale ningún dato.
- **Dependencia y versiones:** un cambio silencioso del modelo puede mover las probabilidades; fijar la versión (por ejemplo, la 1.13.0) y repetir la medición al cambiarla.
- **Información reciente:** el producto salió en septiembre de 2026 y las cifras de velocidad y costo son del proveedor; revisar la documentación oficial y el acceso real a la API antes del hackathon.
- **Idioma y formato:** Jev recibe solo texto; probar con el estado en español y en inglés.
- **Responsabilidad:** aunque un motor externo esté de acuerdo, decide una persona.

Fuentes: DataNorth, “Jev: what it is and why this new model matters”; Requesty, “TypeSafe Jev explained”; nexos.ai, “What is Jev and how to use it?”; arXiv 2609.30216, “Jev in the Wild”. Banco de pruebas propio: `bench/bench.py`.

ENTREGABLE · VALOR DE NEGOCIO, ESCALABILIDAD E IMPLEMENTACIÓN

14. Valor de negocio, escalabilidad e implementación

Valor para COSCO SHIPPING

Menor costo por servicio

Se paga solo la confiabilidad que el envío necesita. Ahorro estimable con el backtest: suma de la diferencia de costo esperado entre lo elegido y lo recomendado.

Mayor puntualidad

Menos retrasos en los envíos críticos y avisos anticipados al cliente cuando hay riesgo.

Tiempo del equipo

La comparación manual pasa de minutos a segundos; el equipo dedica su tiempo a excepciones y clientes.

Consistencia y trazabilidad

Misma solicitud, misma recomendación; cada decisión queda registrada con su porqué y la versión del modelo.

Poder de negociación

Datos objetivos por corredor y tipo de carga para negociar tarifas y planes de mejora.

Margen hoy y relación mañana

El costo esperado protege el margen de cada envío; la puntualidad protege la recompra del cliente.

Escalabilidad

- **Más volumen:** la recomendación es un cálculo de milisegundos por proveedor; el entrenamiento es nocturno.

- **Más proveedores y corredores:** las estadísticas se calculan por proveedor × corredor; agregar uno no cambia el diseño.
- **Otros países:** el mismo esquema sirve para otras operaciones terrestres de COSCO cambiando corredores, tarifas y reglas locales.
- **Integración:** la lógica se expone como servicio (API), conectable al sistema de gestión de transporte o al ERP.

Plan de implementación

Fase	Duración	Qué se hace	Criterio para avanzar
0 · Datos	2–4 semanas	Integrar históricos, limpiar, calibrar costos de retraso con el negocio.	Calidad de datos aceptable.
1 · Modo sombra	1–2 meses	El sistema recomienda sin mostrarse; se compara con las decisiones reales.	Ahorro y puntualidad estimados positivos.
2 · Asistido	3 meses	Operaciones ve la recomendación y decide; se registran motivos de rechazo.	Tasa de aceptación y satisfacción del equipo.
3 · Aprendizaje continuo	Permanente	Reentrenamiento, ajustes de pesos con aprobación, fichas para negociación, alertas.	KPIs estables o mejorando.

Indicadores a seguir

Minutos por decisión · % de entregas a tiempo por nivel · costo por servicio · margen por servicio · tasa de aceptación de la recomendación · HHI de concentración · días de detención de contenedores.

VERIFICACIÓN

15. Cumplimiento de entregables y criterios

Entregables definidos por COSCO

Entregable	Dónde se cubre
Prototipo funcional (recomendación o lista corta ordenada)	Secciones 5 y 16: recomendador con Top-3 explicado; pantalla en 5.10.
Base de datos de proveedores y modelo de datos	Sección 4 y página 4 del drawio.
Metodología de puntuación y recomendación	Sección 5, con fórmula y ejemplo numérico.
Ranking y análisis de fortalezas y debilidades	Sección 6: Índice de Dureza, fichas, señales de riesgo y concentración.
Tableros: precios, tránsito, capacidad, vehículos y tendencias	Sección 10.
Demostración con datos históricos y de prueba	Secciones 11 y 12.
Valor de negocio, escalabilidad e implementación (breve)	Sección 14.

Criterios de evaluación

Criterio	Puntos	Cómo lo respondemos
1. Comprensión del problema	15	AS-IS, tensiones entre los siete factores, necesidades de operaciones y gerencia, casos difíciles (secciones 2, 7, 8).
2. Calidad de la recomendación	20	Filtros duros, siete factores en el costo esperado, niveles de servicio, relajación escalonada y reglas de revisión (5, 7).
3. Metodología y transparencia	20	Fórmula explícita en pesos, desglose por componente, ranking determinista, SHAP, versión del modelo en cada decisión (5, 9).
4. Funcionamiento y demostración	20	Prototipo de punta a punta, seis casos de demostración, reproducción en vivo (11, 16).
5. Análisis y visualización	10	Ranking por Dureza, fichas, señales de riesgo y siete tableros (6, 10).
6. Valor de negocio y viabilidad	10	Valor concreto, escalabilidad y plan por fases con criterios de avance (14).
7. Comunicación	5	Narrativa del lazo de control, ejemplo numérico de tres niveles y demostración guiada.

Preguntas del reto y su respuesta corta

Pregunta	Respuesta
¿Qué hace que un proveedor sea el más adecuado para un envío?	Ser factible y tener el menor costo total esperado para ese corredor, carga y nivel.
¿Qué pesa más cuando los factores chocan?	Lo decide el costo del retraso del nivel de servicio.
¿Qué pasa si el mejor no tiene capacidad o vehículo?	Se descarta con motivo; relajación escalonada; escalamiento si no hay alternativa.
¿Qué tan representativo es un historial corto?	Poco: suavizado bayesiano, intervalo de confianza y penalización por incertidumbre.
¿Cómo se refleja que un proveedor mejore o empeore?	Decaimiento temporal, actualización en tiempo real y alertas de tendencia.
¿Qué información falta o es poco confiable?	Indicador de calidad de datos y advertencia explícita en la recomendación.
¿Qué necesita ver operaciones para confiar?	Desglose del costo, los siete factores, alertas, descartados y nivel de confianza.
¿Cómo se explica por qué uno quedó por encima de otro?	Diferencia por componente del costo esperado y factores clave de cada predicción.
¿Qué le sirve a la gerencia?	Tableros, fichas, Dureza por corredor, concentración y aceptación de recomendaciones.
¿Qué señales indican riesgo?	Las ocho señales de la sección 6.
¿Qué pasa si se concentran los servicios?	HHI, umbral de participación, penalización y alerta.

IMPLEMENTACIÓN DEL PROTOTIPO

16. Arquitectura técnica y plan de trabajo

Componentes

Componente	Tecnología propuesta
Datos	SQLite o PostgreSQL con el modelo de la sección 4; archivos parquet para análisis.
Modelos	Python, pandas, CatBoost/LightGBM, SciPy (estadística bayesiana), SHAP.
Motor de recomendación	Módulo Python con una función pública `recomendar(solicitud, nivel)`; en producción, expuesto como API.
Interfaz del operador	Aplicación web (Streamlit en el prototipo).
Tableros	Pestaña en la misma aplicación o Power BI sobre la misma base.

Contrato del motor

Acordar esta salida desde el inicio permite que interfaz y modelos se construyan en paralelo:

```
{
  "ranking": [{"proveedor": "B", "costo_esperado": 4838787,
               "desglose": {"precio": 4300000, "retraso": 195652, "incidente": 40000,
                            "incertidumbre": 203135, "concentracion": 100000},
               "p_a_tiempo": 0.92, "transito_p50_h": 24, "transito_p90_h": 30,
               "n_servicios_corredor": 95, "alertas": ["Concentra 41 % del volumen"]},
...],
  "descartados": [{"proveedor": "D", "motivo": "Sin capacidad para la fecha"}],
  "requiere_revision": true, "motivo_revision": "Empate técnico",
  "sugerencia_prueba": null, "modelo_version": "v1.3"
}
```

Roles del equipo

Perfil	Responsabilidad
Ingeniería de sistemas	Modelos, motor de recomendación, integración.
Ingeniería de control	Lazo de retroalimentación, estabilidad, simulación en vivo, ajuste de pesos.
Ingeniería mecatrónica	Interfaz del operador e integración de módulos.
Ingeniería mecánica	Datos (limpieza o simulador) y tableros.
Negocios	Niveles de servicio, procesos BPMN, valor de negocio, plan de implementación, presentación.

Plan de 20 horas

Horas	Entregable
0 – 1	Exploración de datos y contrato del motor.
1 – 4	Limpieza o simulador; modelo de datos cargado.
4 – 8	**Versión 1 de punta a punta:** filtros + bayesiano + costo esperado + interfaz básica.

Horas	Entregable
8 – 12	M1 y M2, validación temporal, explicación, backtest.
12 – 15	Tableros y reproducción en vivo.
15 – 17	Congelar funciones; probar los casos de demostración y los casos difíciles.
17 – 20	Presentación, video de respaldo de la demo y ensayo.

ANEXO

Glosario

Costo total esperado	Precio más el costo promedio esperado de retrasos, incidentes, incertidumbre y concentración, en pesos.
P50 / P90	Tiempo de tránsito que se cumple en la mitad / en el 90 % de los casos.
Suavizado bayesiano	Combinar el promedio general con la evidencia propia del proveedor, según cuánta evidencia tenga.
Intervalo de confianza	Rango donde probablemente está el valor real; es más ancho cuantos menos datos hay.
Decaimiento temporal	Los servicios antiguos pesan menos que los recientes.
SHAP	Método que indica cuánto aportó cada variable a una predicción concreta.
Calibración	Ajuste para que una probabilidad predicha de 80 % se cumpla en el 80 % de los casos.
HHI	Índice de concentración: suma de las participaciones al cuadrado.
Human in the loop	Diseño en el que una persona revisa y toma la decisión final.
BPMN	Notación estándar para modelar procesos de negocio. Piscinas = organizaciones; carriles = roles; flujos de mensaje = comunicación entre organizaciones.
Detención	Cobro por días adicionales de uso del contenedor fuera del tiempo libre pactado.

Las cifras de los ejemplos son ilustrativas y no representan tarifas ni desempeño real de ningún proveedor. Los parámetros (costos de retraso, umbrales, pesos) se calibran con COSCO SHIPPING durante la fase 0.