GUÍA PARA TODO EL EQUIPO

Los datos del proyecto, explicados sin tecnicismos

Esta guía explica qué información necesita el sistema, cómo está organizada y cómo se ve en la práctica. No hace falta saber de bases de datos.

1. La idea en un minuto

> **Piensen en un libro de Excel con 16 hojas.** Cada hoja guarda un tipo de información (clientes, proveedores, tarifas, servicios…). Cada fila es «una cosa» (un cliente, un servicio). Para que las hojas se conecten, cada fila tiene un **código único** (por ejemplo, el proveedor P05) y las demás hojas lo usan para señalarlo en vez de repetir su nombre.
>
> A eso se le llama «modelo entidad-relación»: **entidad** = una hoja, **relación** = el código que la conecta con otra. Eso es todo. El diagrama del PDF es solo el mapa de qué hoja se conecta con cuál.

2. Un viaje real, de principio a fin

Así se reparten los datos de **un solo pedido** tomado de nuestros datos de ejemplo. Las flechas indican «mira el código en la otra hoja».

Solicitud R000077
Cliente K007 pide llevar carga general de Cartagena a Bogota, nivel Estandar. Cobra 5,300,000 COP.

→

Servicio S000079
Se asignó al proveedor P05 (Economica del Sur) por 4,004,000 COP.

→

Resultado
Llegó tarde; costo final 4,454,000 COP. El cliente calificó 2 de 3, causa: proveedor.

Del servicio se desprenden además los **eventos** del viaje (GPS y novedades) y, al cerrar, el sistema **actualiza la hoja de vida** del proveedor P05. Por eso el servicio es la hoja más importante: cada fila le enseña algo al sistema.

solicitud_id	cliente_id	corredor_id	tipo_vehiculo_req	tipo_carga	peso_ton	fecha_cargue	plazo_entrega	nivel_servicio	tarifa_cliente	fase
R000077	K007	C4	V20	general	14.8	2025-11-09T06:00	2025-11-10T19:12	Estandar	5300000	historico

servicio_id	solicitud_id	proveedor_id	precio_pactado	cargue_real	entrega_planeada	entrega_real	a_tiempo	costo_final	dias_detencion	estado
S000079	R000077	P05	4004000	2025-11-09T06:42	2025-11-10T19:12	2025-11-11T10:04	0	4454000	1	ENTREGADO

servicio_id	tipo	fecha_hora	detalle
S000079	GPS	2025-11-10T00:55	hito 1
S000079	GPS	2025-11-10T19:08	hito 2
S000079	NOVEDAD	2025-11-10T13:56	demora en ruta

servicio_id	canal	puntaje	causa
S000079	WhatsApp	2	proveedor

3. Las 16 hojas en tres grupos

Catálogos (8)
Lo que cambia poco y es la base: clientes, corredores, tipos de vehículo, proveedores, certificaciones, flota, tarifas y capacidad.

Operación (4)
Lo que pasa cada día: solicitudes, servicios, eventos en ruta y opinión del cliente. **De aquí aprende el sistema.**

Inteligencia (4)
Lo que genera el sistema: recomendaciones, decisiones, estadísticas por proveedor y versiones de modelo. **Nadie la llena a mano.**

Indispensable sin esto no se puede hacer una recomendación. Deseable mejora la calidad pero hay sustitutos. Sistema lo calcula el sistema.

4. Hoja por hoja

Clientes Deseable

La lista de empresas que le piden transporte a COSCO.

Quién la llena: COSCO (su base de clientes) · **Nombre técnico:** `cliente`

cliente_id	Código único del cliente (K001, K002...)
nombre	Nombre de la empresa
segmento	importador, exportador o mixto
prioridad	1 = cliente clave, 3 = normal

Ejemplo real de nuestros datos:

cliente_id	nombre	segmento	prioridad
K003	Cliente 003	exportador	3
K007	Cliente 007	exportador	2

Corredores Indispensable

Cada ruta entre un puerto y una ciudad. Es el «tramo» sobre el que se compara a los proveedores.

Quién la llena: COSCO + mapa de rutas · **Nombre técnico:** `corredor`

corredor_id	Código de la ruta (C1, C2...)
origen / destino	Ciudades de salida y llegada
puerto	Puerto donde empieza la ruta
distancia_km	Kilómetros por carretera
riesgo_vial	0 a 1; qué tan difícil es la vía (derrumbes, orden público)

Ejemplo real de nuestros datos:

corredor_id	origen	destino	puerto	distancia_km	riesgo_vial
C1	Buenaventura	Bogota	Buenaventura	519.0	0.75
C2	Buenaventura	Cali	Buenaventura	165.0	0.55
C3	Buenaventura	Medellin	Buenaventura	499.0	0.7

Tipos de vehículo Indispensable

El catálogo de camiones que existen: tractomula 40', 20', reefer, cama baja...

Quién la llena: COSCO · **Nombre técnico:** `tipo_vehiculo`

tipo_vehiculo_id	Código (V40, V20, VRF...)
nombre	Nombre normal del vehículo
capacidad_ton	Toneladas que carga
contenedor	Tamaño del contenedor que lleva (20, 40 o –)

Ejemplo real de nuestros datos:

tipo_vehiculo_id	nombre	capacidad_ton	contenedor
V40	Tractomula 40'	32.0	40
V20	Tractomula 20'	22.0	20
VRF	Reefer 40'	28.0	40

Proveedores Indispensable

Las empresas transportadoras entre las que hay que elegir.

Quién la llena: COSCO · **Nombre técnico:** `proveedor`

proveedor_id	Código único (P01…)
nombre	Nombre comercial
nit	Identificación tributaria
ciudad_base	Dónde opera principalmente
fecha_alta	Desde cuándo trabaja con COSCO
activo	1 si se puede usar hoy, 0 si no

Ejemplo real de nuestros datos:

proveedor_id	nombre	ciudad_base	fecha_alta	activo
P01	Andina Cargo	Bogota	2019-03-01	1
P02	TransPacifico	Cali	2018-06-01	1
P03	Caribe Express	Barranquilla	2017-02-01	1

Certificaciones Indispensable

Permisos especiales de cada proveedor: mercancía peligrosa (IMO), refrigerada (REEFER) o sobredimensionada. Sin el permiso NO puede hacer ese servicio.

Quién la llena: Proveedores / COSCO · **Nombre técnico:** `certificacion`

proveedor_id	A qué proveedor pertenece
tipo	IMO, REEFER o SOBREDIMENSIONADA
vigente_hasta	Fecha en que vence

Ejemplo real de nuestros datos:

proveedor_id	tipo	vigente_hasta
P03	REEFER	2027-12-31
P06	SOBREDIMENSIONADA	2027-12-31
P08	REEFER	2027-12-31

Flota Indispensable

Cuántos vehículos de cada tipo tiene cada proveedor.

Quién la llena: Proveedores · **Nombre técnico:** `flota`

proveedor_id	Proveedor
tipo_vehiculo_id	Tipo de vehículo
cantidad	Cuántos tiene

Ejemplo real de nuestros datos:

proveedor_id	tipo_vehiculo_id	cantidad
P05	V20	10
P05	V40	18
P05	VSE	6

Tarifas Indispensable

El precio que cobra cada proveedor por cada ruta y tipo de vehículo, y desde cuándo vale. Si no hay tarifa, ese proveedor no cubre esa ruta.

Quién la llena: COSCO (cotizaciones) · **Nombre técnico:** `tarifa`

proveedor_id	Proveedor
corredor_id	Ruta
tipo_vehiculo_id	Vehículo
precio_cop	Precio en pesos colombianos
vigente_desde / hasta	Periodo en que ese precio es válido

Ejemplo real de nuestros datos:

proveedor_id	corredor_id	tipo_vehiculo_id	precio_cop	vigente_desde	vigente_hasta
P05	C1	V40	2855000	2025-11-01	2026-01-31
P05	C1	V40	2890000	2026-02-01	2026-04-30
P05	C1	V40	2924000	2026-05-01	2026-07-31
P05	C1	V40	2959000	2026-08-01	

Capacidad en el tiempo Deseable

Una «foto» de cuántos vehículos libres tenía cada proveedor en una fecha. Se guardan muchas fotos para saber qué se sabía en cada momento.

Quién la llena: Proveedores (reporte semanal o diario) · **Nombre técnico:** `capacidad_snapshot`

proveedor_id	Proveedor
tipo_vehiculo_id	Vehículo
fecha_hora	Cuándo se tomó la foto
unidades_disponibles	Cuántos vehículos libres había

Ejemplo real de nuestros datos:

proveedor_id	tipo_vehiculo_id	fecha_hora	unidades_disponibles
P05	V40	2025-11-01T06:00	9
P05	V40	2025-11-08T06:00	5
P05	V40	2025-11-15T06:00	9

Solicitudes Indispensable

Cada pedido de transporte de un cliente: qué, de dónde a dónde, para cuándo y con qué nivel de urgencia.

Quién la llena: Operaciones de COSCO · **Nombre técnico:** `solicitud`

solicitud_id	Código del pedido
cliente_id / corredor_id	Quién lo pide y en qué ruta
tipo_vehiculo_req	Vehículo que necesita
tipo_carga	general, refrigerada, peligrosa o sobredimensionada
peso_ton	Peso en toneladas
fecha_cargue	Cuándo hay que recoger la carga
plazo_entrega	Fecha límite de entrega
nivel_servicio	Flexible, Estandar o Urgente
tarifa_cliente	Lo que COSCO le cobra al cliente (sirve para calcular el margen)
fase	historico (para aprender) o prueba (para la demostración)

Ejemplo real de nuestros datos:

solicitud_id	cliente_id	corredor_id	tipo_vehiculo_req	tipo_carga	peso_ton	fecha_cargue	plazo_entrega	nivel_servicio	tarifa_cliente	fase
R000077	K007	C4	V20	general	14.8	2025-11-09T06:00	2025-11-10T19:12	Estandar	5300000	historico

Servicios ejecutados Indispensable

Lo que realmente pasó: a qué proveedor se le asignó el pedido y si cumplió. Esta es la tabla MÁS importante: de aquí aprende el sistema.

Quién la llena: Operaciones de COSCO · **Nombre técnico:** `servicio`

servicio_id	Código del servicio
solicitud_id / proveedor_id	Qué pedido y quién lo hizo
precio_pactado	Precio acordado con el proveedor
cargue_real	Cuándo cargó de verdad
entrega_planeada / entrega_real	Cuándo debía y cuándo entregó
a_tiempo	1 si llegó a tiempo, 0 si se retrasó
costo_final	Costo real: precio + detención + incidentes
dias_detencion	Días extra de contenedor retenido
estado	ENTREGADO, CANCELADO o RECHAZADO

Ejemplo real de nuestros datos:

servicio_id	solicitud_id	proveedor_id	precio_pactado	cargue_real	entrega_planeada	entrega_real	a_tiempo	costo_final	dias_detencion	estado
S000079	R000077	P05	4004000	2025-11-09T06:42	2025-11-10T19:12	2025-11-11T10:04	0	4454000	1	ENTREGADO

Eventos en ruta Deseable

Lo que ocurre durante el viaje: puntos del GPS, novedades, incidentes, daños.

Quién la llena: GPS / proveedores / operaciones · **Nombre técnico:** `evento_servicio`

servicio_id	A qué servicio pertenece
tipo	GPS, NOVEDAD, INCIDENTE o DANO
fecha_hora	Cuándo ocurrió
detalle	Texto corto

Ejemplo real de nuestros datos:

servicio_id	tipo	fecha_hora	detalle
S000079	GPS	2025-11-10T00:55	hito 1
S000079	GPS	2025-11-10T19:08	hito 2
S000079	NOVEDAD	2025-11-10T13:56	demora en ruta

Opinión del cliente Deseable

Calificación de 1 clic (😊😐☹️) y su causa. Es opcional: no todos los servicios la tienen.

Quién la llena: Cliente por WhatsApp / operador · **Nombre técnico:** `feedback`

servicio_id	Servicio calificado
canal	WhatsApp u operador
puntaje	1 = malo, 2 = regular, 3 = bueno
causa	proveedor, cliente, puerto o clima (si fue negativo)

Ejemplo real de nuestros datos:

servicio_id	canal	puntaje	causa
S000079	WhatsApp	2	proveedor

Recomendaciones Sistema

Lo que el sistema sugirió para cada pedido (Top-3 y su explicación). Se guarda para poder auditar.

Quién la llena: El sistema · **Nombre técnico:** `recomendacion`

recomendacion_id	Código
solicitud_id	Pedido
modelo_version	Versión del modelo que lo calculó
top3_y_desglose	Los tres proveedores y el detalle de costos
confianza	0 a 1
requiere_revision	1 si una persona debe mirarlo con detalle

Ejemplo real de nuestros datos:

La llena el sistema; empieza vacía.

Decisiones Sistema

Lo que la persona decidió finalmente, si aceptó la recomendación y por qué no.

Quién la llena: Operador en la interfaz · **Nombre técnico:** `decision`

proveedor_elegido	Quién fue elegido
usuario	Quién decidió
acepto_recomendacion	1 si siguió la sugerencia
motivo	Si no la siguió: precio, relación, capacidad, etc.

Ejemplo real de nuestros datos:

La llena el sistema; empieza vacía.

Estadísticas del proveedor Sistema

La «hoja de vida» calculada de cada proveedor en cada ruta: puntualidad, tiempos, índice de dureza. Se recalcula con cada servicio.

Quién la llena: El sistema · **Nombre técnico:** `estadistica_proveedor`

alfa / beta	Números internos del cálculo bayesiano
p_tarde	Probabilidad estimada de que se retrase
transito_p50_h / p90_h	Horas típicas y pesimistas de viaje
n_servicios	Cuántos servicios respaldan estos números
indice_dureza	Nota de 0 a 10 de resistencia del proveedor

Ejemplo real de nuestros datos:

La llena el sistema; empieza vacía.

Versiones del modelo Sistema

El registro de cada modelo o juego de pesos que ha usado el sistema y quién lo aprobó.

Quién la llena: El sistema / gerencia · **Nombre técnico:** `modelo_version`

modelo_version	Nombre de la versión
metricas_validacion	Qué tan bien funcionó al probarlo
aprobado_por	Quién lo autorizó

Ejemplo real de nuestros datos:

La llena el sistema; empieza vacía.

5. De dónde salen los datos: los inventamos

> COSCO confirmó que **no entregará datos**. Por eso todo es sintético, y eso no es un defecto si se hace con método: lo importante es que los datos sean **creíbles**, que **cuenten historias** que el sistema pueda descubrir y que **se declare con honestidad** qué es real y qué es inventado.

Tres capas de datos

1 · Semilla (historia)
Un año de operación: ~6.100 servicios, 12 proveedores, 8 rutas. Cada proveedor tiene una «historia» (uno se degrada en agosto, otro mejora en junio, uno es nuevo…). Se genera una vez con `generate.py`.

2 · En vivo
Durante la demo se agregan días nuevos con `en_vivo.py`: llegan pedidos, se asignan y se cierran con resultados. Así el público ve cómo reacciona el sistema.

3 · Eventos inyectados
Con una orden se «daña» a un proveedor desde una fecha (por ejemplo, Caribe Express llega tarde 60 % de las veces). Sirve para probar que el sistema se da cuenta y cuánto tarda.

Comandos

Crear la historia	`python seed/generate.py --sucio` (genera la base limpia, una base con errores para practicar limpieza y un archivo de «verdad oculta» solo para evaluar).
Agregar días en vivo	`python seed/en_vivo.py --dias 14 --pausa 3`
Dañar un proveedor	`python seed/en_vivo.py --dias 10 --evento P03:0.6:2026-10-20` (P03 llega tarde el 60 % desde el 20 de octubre)
Revisar calidad	`python seed/validar_datos.py`
Ver las historias	`python seed/check_story.py`

Qué es real y qué es inventado

Con fuente	Distancias Buenaventura–Bogotá (519 km), –Cali (165 km) y –Medellín (499 km), de una presentación de la Cámara de Comercio de Buenaventura. La existencia de cierres viales y filas de camiones en el corredor del puerto, que explican los retrasos largos. El SICE-TAC (Ministerio de Transporte) como referencia oficial de costos eficientes de transporte de carga.
Aproximado	Distancias de las demás rutas (Cartagena, Santa Marta, Barranquilla): valores razonables, por confirmar con un mapa antes de la presentación.
Inventado	Los proveedores y sus nombres, las tarifas (fórmula de pesos por kilómetro más un fijo, ilustrativa), la puntualidad de cada uno, los clientes, las calificaciones, los incidentes y los costos de retraso.

Frase para la presentación: «Los datos son sintéticos. Las distancias de Buenaventura son reales; los precios y el desempeño de los proveedores se simularon con supuestos explícitos que COSCO puede reemplazar con sus datos reales sin cambiar el sistema.»

6. Reglas de calidad de los datos

Los datos inventados también deben cumplir reglas de calidad; si no, el sistema aprendería de basura. Usamos las **seis dimensiones clásicas de calidad de datos** (exactitud, completitud, consistencia, oportunidad, unicidad y validez, según IBM, Dagster y otras guías) y las aplicamos a nuestro caso con **35 reglas automáticas** en `seed/validar_datos.py`.

Unicidad	**Cada cosa aparece una sola vez.** Sin servicios repetidos, sin el mismo proveedor escrito de dos formas, sin precios que se solapen para la misma ruta y fecha.
Completitud	**No falta lo esencial.** Todo servicio entregado trae fechas, si llegó a tiempo y su costo; todo proveedor activo tiene flota y tarifas; toda decisión que rechaza la recomendación trae motivo.
Validez	**Los valores tienen forma y rango razonables.** Fechas bien escritas, pesos que caben en el vehículo, precio por kilómetro entre 2.000 y 25.000 pesos (detecta tarifas multiplicadas por mil), puntaje de 1 a 3, velocidad promedio entre 3 y 90 km/h, detención de 0 a 15 días.
Consistencia	**Las hojas no se contradicen.** Todo código apunta a algo que existe; la entrega es posterior al cargue; «a tiempo» coincide con las fechas; un servicio cancelado no tiene entrega; la detención solo ocurre con retraso; el costo final nunca es menor al precio pactado; los eventos de ruta ocurren dentro del viaje; la capacidad no supera la flota.
Reglas del negocio	**Se respetan las reglas duras.** Carga refrigerada, peligrosa o sobredimensionada solo la mueve un proveedor con esa certificación; el proveedor debe tener el vehículo y una tarifa en esa ruta; no puede trabajar antes de su fecha de alta; el precio pactado debe ser una tarifa real de ese proveedor.
Exactitud / realismo	**Se parece al mundo real.** Distancias de Buenaventura iguales a las de la fuente; puntualidad global entre 60 % y 92 %; margen al cliente razonable; pocas solicitudes Urgentes (menos del 35 %); menos solicitudes en fines de semana.
Oportunidad	**Nada del futuro.** Un dato «histórico» no puede traer entregas posteriores al corte, y la capacidad se guarda con una foto por semana para saber qué se sabía en cada fecha.

Resultado de la revisión

Base limpia	33 de 35 reglas cumplidas, **0 críticas fallidas**. Los 2 avisos son esperables: 144 solicitudes (2,5 %) no encontraron proveedor con capacidad o certificación (justo los casos «sin opción ideal» que el sistema debe manejar) y dos combinaciones proveedor–vehículo (proveedores nuevos o pequeños) con pocas fotos de capacidad.
Base con errores	Se detectan los errores sembrados: **9 reglas críticas fallan** (duplicados, entregas anteriores al cargue, valores de «a tiempo» vacíos, nombre de proveedor en otro formato, tarifas multiplicadas por mil y eventos fuera del viaje). Sirve para practicar la limpieza.

> **Lo que encontró el validador en nuestro propio generador:** al principio, algunas entregas marcadas «a tiempo» estaban un minuto fuera del plazo y los retrasos más largos daban velocidades de 3 a 11 km/h. Lo primero era un error nuestro y se corrigió; lo segundo es realista (cierres viales y filas en el puerto de Buenaventura) y se ajustó la regla. Así se usa el validador: **cada vez que cambien el generador, lo ejecutan.**

Supuestos propios por calibrar

Los rangos de precio por kilómetro, velocidad, puntualidad global y margen al cliente son supuestos del equipo, no cifras oficiales. Se pueden refinar con las tarifas del SICE-TAC si el tiempo lo permite; si alguien del jurado pregunta, la respuesta es que son parámetros editables en `seed/config.py`.

Fuentes

Cámara de Comercio de Buenaventura (presentación en el foro «Movilidad hacia el Pacífico», Universidad Icesi): distancias y cierres viales. Ministerio de Transporte: SICE-TAC. IBM Docs «Data quality dimensions» y Dagster «Data quality checks»: dimensiones de calidad.

Los ejemplos del documento son datos sintéticos generados para el proyecto. Plantilla en Excel para completar: **plantilla_datos.xlsx**.